

Aufgabe 1: Schmucknachrichten

Teilnahme-ID: 74130

Bearbeiter/-in dieser Aufgabe:
Matthew Greiner

April 28, 2025

Contents

1	Teilaufgabe A	1
1.1	Lösungsidee	1
1.2	Umsetzung	2
1.3	Komplexitätsanalyse	4
1.4	Beispiele	5
1.5	Quellcode	7
2	Teilaufgabe B	9
2.1	Lösungsidee	9
2.2	Strategie 1: Heuristische n-näre Huffman Modifikation mit greedy Kostenzuweisung	9
2.2.1	Kernidee	9
2.2.2	Umsetzung	10
2.2.3	Komplexitätsanalyse	10
2.2.4	Beispiele	11
2.2.5	Quellcode	18
2.3	Strategie 2: Modifizierung Golin/Li Algorithmus	19
2.3.1	Kernidee	19
2.3.2	Umsetzung	21
2.3.3	Komplexitätsanalyse	22
2.3.4	Beispiele	22
2.3.5	Quellcode	29
2.4	Strategie 3: Dynamische Programmierung Golin/Rote	32
2.4.1	Kernidee	32
2.4.2	Umsetzung	34
2.4.3	Komplexitätsanalyse	37
2.4.4	Beispiele	38
2.4.5	Quellcode	47
2.5	Vergleich der Strategien	57

1 Teilaufgabe A

1.1 Lösungsidee

Verständnis der Aufgabe

Die Grundidee dieser Aufgabe ist es einen gegebenen Unicode-Text mit Hilfe von Perlen zu kodieren, die alle denselben Durchmesser haben. Die Anzahl der Farben der Perlen ist gegeben und beträgt mindestens zwei. Das Ziel ist es, den gegebenen Text so mit den Perlen zu kodieren, dass eine möglichst

kurze Perlenkette daraus gemacht werden kann. Die verwendete Codetabelle für die präfixfreie Kodierung und die Gesamtlänge der Botschaft muss am Ende ausgegeben werden.

Überlegungen zum Lösungsansatz

Da der Durchmesser aller Perlen gleich ist, muss die Anzahl der verwendeten Perlen in der Kodierung minimiert werden, um die Perlenkette möglichst kurz zu halten. Da jedes Zeichen aus dem Eingabetext einzeln durch einen Code aus Perlen dargestellt werden muss, macht es Sinn, dass häufig verwendete Zeichen kurze Codes und selten verwendete Zeichen längere Codes bekommen. Diese Anforderungen eine **optimale präfixfreie Kodierung basierend auf Zeichenhäufigkeiten zur Minimierung der Gesamtlänge** ist eine klassische Anwendung der Huffman-Kodierung, die auch als Basis für die Lösung dieser Teilaufgabe verwendet wird.

Die Huffman-Kodierung ist ein Algorithmus, der unter folgenden Bedingungen eine optimale binäre Kodierung liefert:

1. Jedes Zeichen bekommt einen eindeutigen Binärcode
2. Die Nachricht ist verlustfrei und eindeutig dekodierbar
3. Die durchschnittliche Länge (gewichtet nach Häufigkeit) wird minimiert

Da diese Bedingungen genau zu dieser Aufgabe passen, eignet sich diese Kodierung für diese Aufgabe gut. Standardmäßig funktioniert die Huffman-Kodierung aber binär. Da wir die gegebene Nachricht evtl. aber mit mehr als zwei Farben von Perlen kodieren müssen, muss der Algorithmus auf eine **n-ären** Huffman-Kodierung erweitert werden. Eine solche Verallgemeinerung des Algorithmus wurde bereits im Originalpaper von Huffman [1] beschrieben.

Diese Erweiterung des Algorithmus funktioniert analog zu der binären Huffman-Kodierung, nur die Erstellung des Huffman-Baums muss angepasst werden. Bei der normalen Huffman-Kodierung werden zunächst die zu kodierenden Zeichen in Knoten gespeichert. Dann werden die **zwei** Knoten mit den geringsten Häufigkeiten kombiniert und als Kinder von einem neuen Knoten gespeichert. Die "Häufigkeit" des neuen Knotens wird als Summe der beiden Häufigkeiten der Kinder festgelegt. Dieser Prozess wird wiederholt, bis nur noch ein Knoten übrig ist. Dieser ist dann die Wurzel des neuen Baums. Das bedeutet bei jeder Kombination verringert sich die Anzahl der betrachteten Knoten um eins. Der Baum wird also "bottom-up" erstellt, und garantiert somit eine optimale Kodierung (im Gegensatz zur Shannon-Fano-Kodierung, die einen Baum "top-down" erstellt und nicht immer die optimale Kodierung findet).

Der Unterschied zu der **n-nären** Huffman-Kodierung ist nur, dass die n Knoten mit den geringsten Häufigkeiten kombiniert werden und nicht nur zwei. Das hat zur Folge, dass mit jeder Kombination die Anzahl der betrachteten Knoten nun um $n - 1$ sinkt. Daher muss gezielt darauf geachtet werden, dass nach allen Kombinationen nur noch ein Knoten übrigbleibt. Der Aufbau des n -nären Baums funktioniert, wenn folgende Gleichung erfüllt ist:

$$N \bmod (n - 1) = 1 \quad (N = \text{Anzahl der Knoten}) \quad (1)$$

Wenn das nicht der Fall ist, können Platzhalterknoten hinzugefügt werden, die die Häufigkeit 0 haben, bis diese Bedingung erfüllt ist. Bei der Erstellung der Codetabelle wird der Graph (analog zur Standard Huffman-Kodierung) z.B. mit Tiefensuche traversiert. Dabei wird jeder Kante von einem Elternknoten zu einem Kindknoten eindeutig eine Zahl (z.B. von 0 bis $k-1$) zugeordnet. Eine Zahl repräsentiert in dieser Aufgabe eine Perlenfarbe. In der binären Version werden nur die Zahlen 0 und 1 benutzt.

1.2 Umsetzung

Um diesen Algorithmus umzusetzen und somit die Aufgabe zu lösen, wird wie folgt vorgegangen (die Nummerierung entspricht auch der Nummerierung im Quellcode):

1. Einlesen des Eingabetextes und der Anzahl der verschiedenen Perlenfarben

Da alle Eingaben in Dateien vorliegen, welche nur 3 Zeilen haben, werden sie zunächst eingelesen und an den Zeilenumbrüchen getrennt. Der Text sowie die Anzahl der verschiedenen Perlenfarben werden anschließend in entsprechenden Variablen gespeichert.

2. Analyse der Häufigkeit der Zeichen im Text

Um zu zählen, wie häufig die Zeichen in dem Text vorkommen, wird über alle Zeichen des Textes iteriert. Die Werte werden in einer HashMap gespeichert, wobei das Zeichen den Schlüssel und die Anzahl seines Vorkommens im Text den zugehörigen Wert darstellt.

3. Erstellung eines n -ären Huffman-Baums basierend auf den Häufigkeiten

Um den Baum zu erstellen, wird eine Klasse Node definiert, die einen Knoten im Huffman-Baum repräsentiert. Diese Klasse speichert das Zeichen, seine Häufigkeit, eine Liste seiner Kindknoten und einen Marker, welcher angibt, ob der Knoten ein Blatt im Baum ist. Die einzelnen Knoten werden in einer PriorityQueue verwaltet, welche in Java als Min-Heap implementiert ist. Dadurch stehen die Knoten mit der geringsten Häufigkeit immer oben in der Warteschlange und diese Datenstruktur eignet sich daher gut, da für die Erstellung des Baums jeweils die n Knoten mit den **geringsten** Häufigkeiten kombiniert werden.

Dies ist was den Huffman Algorithmus zu einem *greedy* Algorithmus macht. Er trifft in jedem Schritt eine lokal optimale Entscheidung (kombiniere die n unwahrscheinlichsten Knoten), die nachweislich zur globalen optimalen Lösung führt.

Ablauf

Zunächst werden die Zeichen des Text in Blattknoten gespeichert und in die PriorityQueue eingefügt. Um aus diesen Knoten den Huffman-Baum zu konstruieren, kann man Platzhalter-Knoten einführen (siehe 1.1), allerdings gibt es auch einen Weg diese zusätzlichen Knoten zu vermeiden:

Statt Platzhalter mit der Häufigkeit 0 zu erzeugen, werden beim ersten Merging nicht zwingend n Knoten kombiniert, sondern eine bestimmte Anzahl r . Dieses r muss so gewählt werden, dass nach der ersten Kombination eine Gesamtanzahl an Knoten entsteht, mit der sich der Rest des Baums in gleichmäßigen n -er Gruppen weiterbauen lässt.

Es gilt die Gleichung 1.

Wenn ein n -ärer Baum gefordert ist, ist N die Anzahl an Blattknoten in der Queue. Die Gleichung muss auch nach dem ersten Merge mit r Knoten gelten:

$$(N - r + 1) \bmod (n - 1) = 1$$

Nach r umstellen ergibt:

$$\begin{aligned} N - r &\equiv 0 \pmod{n - 1} \\ \Rightarrow r &= N \bmod (n - 1) \end{aligned}$$

r muss mindestens 2 sein, damit ein Merge Sinn macht, daher wird:

$$r = (N - 2) \bmod (n - 1) + 2 \tag{2}$$

in der Implementierung verwendet.

In der Implementierung wird r also einmalig für den ersten Merge verwendet. Danach werden Gruppen zu je n Knoten kombiniert, bis nur noch ein Knoten übrig ist, der dann die Wurzel des Huffman-Baums ist.

4. Erzeugen der Codetabelle anhand des Baums

Zur Speicherung der Codetabelle wird eine HashMap verwendet, in der die Zeichen als Schlüssel und ihre zugehörige n -äre Huffman-Kodierung als Werte abgelegt sind. Die Werte werden dann schrittweise bei der Traversierung des Baums aufgebaut.

Um die Kodierung für jedes Zeichen zu finden, wird der Baum mit einer rekursiven Tiefensuche (DFS) durchlaufen. Dabei wird bei jedem rekursiven Aufruf der bisher zurückgelegte Pfad vom Wurzelknoten bis zum aktuellen Knoten als String übergeben.

Weil es sich um eine n -äre Huffman-Kodierung handelt, werden die Kanten des Baums durch die Ziffern 0 bis $n-1$ beschrieben. Die Ziffern entsprechen allgemein formuliert, den Kodierungsbuchstaben, die in diesem Fall die jeweilige Perlenart bzw. Perlenfarbe darstellt. Bei jedem Abstieg zu einem Kindknoten wird an die aktuelle Zeichenkette die Position des jeweiligen Kindes im Elternknoten angehängt. Wenn ein Blattknoten erreicht wird, also ein Knoten, der tatsächlich ein Zeichen repräsentiert und keine weiteren Nachfolger besitzt, wird der aktuell aufgebaute Pfad als Kodierung für dieses Zeichen in der Codetabelle gespeichert.

5. Berechnung der Gesamtlänge der kodierten Nachricht

Für die Berechnung der Gesamtlänge der kodierten Nachricht wird die Häufigkeit jedes Zeichens (bereits in Schritt 2 bestimmt) mit der Länge seines entsprechenden Huffman-Codes multipliziert. Die Gesamtlänge ergibt sich aus der Summe dieser Produkte multipliziert mit dem Durchmesser einer Perle.

6. Ausgabe der Codetabelle und der Gesamtlänge

Die Tabelle wird nach Code-Länge und Frequenz sortiert (optional, allerdings ein "nice to have", um direkt ablesen zu können, welche Zeichen am meisten vorkommen, wenn dies auch ausgegeben wird, was in dieser Implementierung gemacht wird). Anschließend wird sie formatiert ausgegeben sowie die Gesamtlänge der kodierten Nachricht aus 5.

1.3 Komplexitätsanalyse

Nun wird die Komplexität der einzelnen Schritte des Algorithmus betrachtet. Dabei ist:

- L die Länge des Eingabetextes,
- k die Anzahl der verschiedenen Zeichen (in dieser Dokumentation auch als Quellsymbole bezeichnet),
- n die Basis des Huffman-Baums (Anzahl erlaubter Kindknoten je Knoten).

Schritt	Laufzeit	Speicherbedarf
Einlesen der Datei	$\mathcal{O}(L)$	$\mathcal{O}(L)$
Häufigkeitsanalyse	$\mathcal{O}(L)$	$\mathcal{O}(k)$
Aufbau des Huffman-Baums	$\mathcal{O}(k \log k)$	$\mathcal{O}(k)$
Generieren der Codetabelle	$\mathcal{O}(k)$	$\mathcal{O}(k)$
Berechnung der Gesamtlänge	$\mathcal{O}(k)$	$\mathcal{O}(1)$
Ausgabe Codetabelle (mit Sortierung)	$\mathcal{O}(k \log k)$	$\mathcal{O}(k)$
Gesamt	$\mathcal{O}(L + k \log k)$	$\mathcal{O}(L + k)$
Dominante Terme	$\mathcal{O}(L)$ potentiell langer Text $\mathcal{O}(k \log k)$ wegen Heap Operation/Sortierung	

Table 1: Laufzeit- und Speicherkomplexität Teilaufgabe A

- **Einlesen und Häufigkeitsanalyse:** Beide Vorgänge durchlaufen den Text vollständig und brauchen daher eine Laufzeit von $\mathcal{O}(L)$.
- **Baumkonstruktion:** Wegen der Prioritätswarteschlange (Min-Heap) mit k Blattknoten entstehen $\frac{k-1}{n-1}$ Merges. Jede Insert- und Delete Operation im Heap braucht $\mathcal{O}(\log k)$, was insgesamt zu $\mathcal{O}(k \log k)$ führt.
- **Codetabelle:** Dieser Schritt ist durchläuft jeden Knoten (k Knoten) genau einmal mit DFS (Tiefensuche). Pro Knoten wird eine Schleife über alle n Kinder ausgeführt. Bei der n -ären Kodierung hat der Baum im schlimmsten Fall $\mathcal{O}(k)$ Knoten. Da n eine kleine Konstante ist, beträgt die Laufzeit für diesen Schritt $\mathcal{O}(k)$.
- **Gesamtlänge:** Dieser Schritt iteriert über alle verschiedenen Symbole, die einen Code bekommen und ist daher in $\mathcal{O}(k)$.
- **Ausgabe:** Die Codetabelle wird nach Frequenz und Code-Länge sortiert, was im worst Case ebenfalls $\mathcal{O}(k \log k)$ erfordert. (Ohne die optionale Sortierung wäre das das in $\mathcal{O}(k)$)

Insgesamt ist die Laufzeit dominiert durch das Einlesen des Textes und die Sortiervorgänge beim Baumaufbau mit dem Min-Heap. Der Speicherbedarf ist moderat und wächst linear mit der Eingabegröße sowie der Anzahl unterschiedlicher Zeichen.

Daher erweist sich dieser Algorithmus auch bei größeren Texten als leistungsfähig und garantiert eine optimale Kodierung.

1.4 Beispiele

Hier die Ausgaben des Programmes zu den Beispielen auf der BwInf-Webseite:

1. schmuck0.txt

Codetabelle:

(Jede Ziffer steht für eine Perlenfarbe z.B. könnte '0' rot bedeuten und '1' blau)

```
{
  '□': 111 (Freq: 5)
  'E': 110 (Freq: 5)
  'I': 100 (Freq: 4)
  'N': 101 (Freq: 4)
  'S': 000 (Freq: 3)
  'R': 0100 (Freq: 2)
  'D': 0010 (Freq: 2)
  'L': 0111 (Freq: 2)
  'M': 0110 (Freq: 2)
  'O': 0011 (Freq: 2)
  'C': 01010 (Freq: 1)
  'H': 01011 (Freq: 1)
}
```

Gesamtlänge der Botschaft 113 (in mm) bzw. 11.3cm

2. schmuck00.txt

Codetabelle:

(Jede Ziffer steht für eine Perlenfarbe z.B. könnte '0' rot bedeuten und '1' blau)

```
{
  '□': 21 (Freq: 24)
  'e': 12 (Freq: 18)
  'i': 11 (Freq: 16)
  't': 02 (Freq: 10)
  'n': 01 (Freq: 9)
  'h': 220 (Freq: 8)
  's': 222 (Freq: 8)
  'c': 202 (Freq: 7)
  'l': 201 (Freq: 6)
  'a': 100 (Freq: 4)
  'r': 102 (Freq: 4)
  'd': 001 (Freq: 3)
  'D': 2212 (Freq: 3)
  'u': 2211 (Freq: 3)
  'G': 1012 (Freq: 2)
  'g': 2210 (Freq: 2)
  'm': 2000 (Freq: 2)
  'w': 2002 (Freq: 2)
  'E': 0001 (Freq: 1)
  'P': 0020 (Freq: 1)
  'W': 0002 (Freq: 1)
  'Z': 1010 (Freq: 1)
  'b': 0022 (Freq: 1)
  'f': 1011 (Freq: 1)
  'k': 0021 (Freq: 1)
  'o': 0000 (Freq: 1)
  'A': 20010 (Freq: 1)
  '?': 20011 (Freq: 1)
}
```

Gesamtlänge der Botschaft 372 (in mm) bzw. 37.2cm

3. schmuck01.txt

Codetabelle:

(Jede Ziffer steht für eine Perlenfarbe z.B. könnte '0' rot bedeuten und '1' blau)

```
{  
  '□': 2 (Freq: 85)  
  'e': 0 (Freq: 66)  
  'n': 43 (Freq: 53)  
  'r': 41 (Freq: 34)  
  'i': 40 (Freq: 33)  
  's': 33 (Freq: 26)  
  'a': 31 (Freq: 22)  
  'l': 32 (Freq: 22)  
  't': 30 (Freq: 22)  
  'h': 13 (Freq: 17)  
  'c': 12 (Freq: 15)  
  'g': 11 (Freq: 14)  
  'o': 10 (Freq: 14)  
  'm': 443 (Freq: 13)  
  'u': 442 (Freq: 12)  
  '.': 441 (Freq: 10)  
  'd': 424 (Freq: 9)  
  'k': 440 (Freq: 9)  
  'E': 423 (Freq: 8)  
  ',': 422 (Freq: 8)  
  'D': 344 (Freq: 7)  
  'b': 421 (Freq: 7)  
  'w': 343 (Freq: 6)  
  'ü': 341 (Freq: 5)  
  'I': 340 (Freq: 4)  
  'S': 144 (Freq: 4)  
  'f': 143 (Freq: 4)  
  'p': 142 (Freq: 4)  
  'v': 141 (Freq: 4)  
  'V': 140 (Freq: 3)  
  'F': 4442 (Freq: 3)  
  'O': 4443 (Freq: 3)  
  'ö': 4441 (Freq: 3)  
  'z': 4444 (Freq: 3)  
  'B': 4440 (Freq: 2)  
  'G': 4203 (Freq: 2)  
  'ä': 4204 (Freq: 2)  
  'H': 3420 (Freq: 1)  
  'K': 3421 (Freq: 1)  
  'M': 3422 (Freq: 1)  
  'N': 3424 (Freq: 1)  
  'R': 4200 (Freq: 1)  
  'W': 4202 (Freq: 1)  
  'ß': 3423 (Freq: 1)  
  '...': 4201 (Freq: 1)  
}
```

Gesamtlänge der Botschaft 1150 (in mm) bzw. 115.0cm

1.5 Quellcode

Wichtige Teile des Quellcodes:

1. Einlesung der Daten

```
1 // 1. Read input
private static InputWrapper parseInput(String input) {
3     // Save every line in array of Strings
    String[] lines = input.split("\n");
5     List<Integer> list = new ArrayList<>();
    for (String s : lines[1].split("_")) {
7         list.add(Integer.valueOf(s));
    }
9     return new InputWrapper(Integer.parseInt(lines[0].trim()), lines[2], list);
}
```

2. Häufigkeitsanalyse

```
// 2. Calculate character frequency from input text
private static Map<Character, Long> buildFrequencyMap(String text) {
2     Map<Character, Long> frequencyMap = new HashMap<>();
4     for (char character : text.toCharArray()) {
        frequencyMap.put(character, frequencyMap.getOrDefault(character, 0L) + 1);
6     }
    return frequencyMap;
8 }
```

3. Erstellung eines n-ären Huffman-Baums

```
// 3. Build n-ary Huffman tree and returns root Node
private static Node buildHuffmanTree(Map<Character, Long> frequencyMap, int n) {
2     // PriorityQueue for nodes (sorted by frequency, lower frequency first)
    PriorityQueue<Node> priorityQueue = new PriorityQueue<>();

4     // Create leaf nodes (nodes with characters) and add to priority queue
    for (Map.Entry<Character, Long> entry : frequencyMap.entrySet()) {
6         priorityQueue.add(new Node(entry.getKey(), entry.getValue()));
8     }

10     int numSymbols = priorityQueue.size(); // Number of unique symbols (leaf nodes)

12     // Determine how many nodes should be merged in the first step
    int r;
14     if (numSymbols <= 1) { // Handle edge case: if 0 or 1 symbol, no merging needed
        r = numSymbols;
16     } else {
        // Formula: find smallest valid r so that:
        // After merging r nodes -> remaining nodes + 1 new node
        // -> total node count allows full n-ary merges
20         int remainder = (numSymbols - 2) % (n - 1);
        r = remainder + 2; // Ensures 2 <= r <= n
22     }

24     // Build Huffman tree
    while (priorityQueue.size() > 1) {
26         // Use r only for first merge if needed
        int nodesToMerge = (priorityQueue.size() == numSymbols) ? r : n;
28         // Cannot merge more nodes than available
        nodesToMerge = Math.min(nodesToMerge, priorityQueue.size());

30         if (nodesToMerge < 2) {
            // Should not happen if n > 1
            System.out.println("irgendwas ist broken");
            break;
34         }

36         List<Node> children = new ArrayList<>();
        long mergedFrequency = 0;
```

```

40      // Extract nodes (num of nodesToMerge) with lowest frequencies
42      for (int i = 0; i < nodesToMerge; i++) {
44          Node node = priorityQueue.poll();
45          children.add(node);
46          mergedFrequency += node.frequency;
47      }
48
49      // Create new internal node with new values
50      Node internalNode = new Node(children, mergedFrequency);
51
52      // Add new internal node back to priority queue
53      priorityQueue.add(internalNode);
54  }
55
56      // Last node in queue is root of Huffman tree
57      return priorityQueue.poll();
58  }

```

4. Erzeugen der Codetabelle

```

1  // 4. Generate Huffman codes by traversing tree with recursion and DFS
2  private static void generateCodes(Node node, String currentCode, Map<Character, String>
3      codeTable) {
4      // Base case
5      if (node == null) {
6          return;
7      }
8
9      // If it is a leaf, it represents a character, then assign a code
10     if (node.isLeaf()) {
11         if (node.character != null) {
12             codeTable.put(node.character, currentCode);
13         }
14         // Leaf is reached, stop recursion
15         return;
16     }
17
18     // Assign codes 0 until k-1 to children
19     for (int i = 0; i < node.children.size(); i++) {
20         generateCodes(node.children.get(i), currentCode + i, codeTable);
21     }
22 }

```

5. Berechnung der Gesamtlänge

```

1  // 5. Calculate total length of encoded message
2  private static long calculateTotalLength(Map<Character, String> codeTable,
3      Map<Character, Long> frequencyMap,
4      int diameter) {
5      long totalLength = 0;
6      // Iterate over each Character
7      for (Map.Entry<Character, Long> entry : frequencyMap.entrySet()) {
8          totalLength += entry.getValue() * codeTable.get(entry.getKey()).length();
9      }
10     return totalLength * diameter;
11 }

```

6. Ausgabe

```

1  // Print code table in a readable format
2  private static void printCodeTable(Map<Character, String> codeTable, Map<Character,
3      Long> frequencyMap) {
4      if (codeTable.isEmpty()) {
5          System.out.println("{}");
6          return;
7      }
8      List<Character> sortedKeys = new ArrayList<>(codeTable.keySet());

```



```

8      // Sorting is optional
9      // Sort by length of code
10     sortedKeys.sort((a, b) -> Integer.compare(codeTable.get(a).length(),
11     codeTable.get(b).length()));
12     // Sort by frequency
13     sortedKeys.sort((a, b) -> Long.compare(frequencyMap.get(b), frequencyMap.get(a)));

14     System.out.println("{");
15     for (Character character : sortedKeys) {
16         // Handle special characters for printing
17         String c;
18         c = switch (character) {
19             case '␣' -> "␣";
20             case '"' -> c = "\"";
21             default -> String.valueOf(character);
22         };
23         System.out.println("␣'" + c + "':␣" + codeTable.get(character) + "␣(Freq:␣"
24             + frequencyMap.get(character) + ")");
25     }
26     System.out.println("}");
}

```

2 Teilaufgabe B

2.1 Lösungsidee

Verständnis der Aufgabe

Die Grundidee dieser Aufgabe bleibt gleich: Ein Unicode-Text soll mit Hilfe von Perlen kodiert werden. Allerdings haben die Perlen nun einen unterschiedlichen Durchmesser. Ziel ist es nun, die Gesamtlänge der resultierenden Perlenkette, also die kodierte Nachricht, zu minimieren.

Wenn dieses Problem weiterhin als Optimierungsproblem zu Erstellung einer optimalen, präfixfreien Kodierung (wie bereits im ersten Teil der Aufgabe) betrachtet wird, führt die Einführung variabler Perlendurchmesser zu einer Verallgemeinerung des ursprünglichen Problems. Denn in dieser Erweiterung entspricht der Durchmesser jeder Perle den Kosten des jeweiligen Symbols im Codealphabet. Im Folgenden wird einfachheitshalber, die Perle als Symbol bezeichnet, da diese verwendet werden, um den Text zu kodieren und der Durchmesser der Perle wird als Kosten des Symbols bezeichnet.

Diese Variante ist bekannt als das Problem der **präfixfreien Kodierung mit ungleichen Symbolkosten** (prefix-free coding with unequal letter cost). Im Gegensatz zur klassischen Huffman-Kodierung, die von gleichen Symbolkosten ausgeht, ist diese Verallgemeinerung deutlich komplexer. Es ist bis heute **nicht bekannt**, ob dieses allgemeine Problem in **P** liegt oder **NP-schwer** ist. Allerdings gibt es einen (komplexen) Algorithmus, der die optimale Kodierung findet, wenn die Symbolkosten positive ganze Zahlen sind. Diese Vereinfachung trifft auf diese Teilaufgabe zu, weshalb dieser Algorithmus in Kapitel 2.4 noch eingeführt wird. Somit ist Teilaufgabe B in polynomieller Zeit lösbar.

Überlegungen zum Lösungsansatz

Die aus Kapitel 1 implementierte n-näre Huffman-Kodierung scheitert bei dieser Problemstellung, da die Minimierung der Anzahl der Kodierungsbuchstaben nicht notwendigerweise zur Minimierung der Gesamtkosten führt (die Kosten werden nämlich nicht berücksichtigt).

Im Folgenden werden drei Strategien zur Lösung dieses Problems untersucht:

2.2 Strategie 1: Heuristische n-näre Huffman Modifikation mit greedy Kostenzuweisung

2.2.1 Kernidee

Dieser Ansatz ist vermutlich der intuitivste und am wenigsten aufwendige und ist in zwei Schritte aufgeteilt:

1. Erstellung eines n -nären Huffman Baums

Zunächst wird ein n -närer Huffman Baum mit dem aus Kapitel 1 beschriebenen unveränderten Algorithmus erstellt, bei dem der Baum nur basierend auf den Symbolhäufigkeiten gebaut wird. Dieser Schritt ignoriert also die Symbolkosten und bestimmt nur die Topologie des Baums.

2. Greedy Zuweisung der Kodierungsbuchstaben anhand der Kosten

Bei der Traversierung des Baums zur Erstellung der Codewörter erfolgt die Beschriftung der Kanten (von inneren Knoten mit n Kindern) standardmäßig mit den Ziffern bzw. Kodierungszeichen 0 bis $n - 1$.

Während bei der klassischen Methode aus Kapitel 1 diese Zuweisung oft der Reihenfolge der Kinder folgt (z.B. von links nach rechts), ändert sich dies in dieser Heuristik:

Denn nun erfolgt diese Zuweisung greedy nach folgendem Prinzip:

Die Kante, die zum Teilbaum mit der höchsten Häufigkeit führt, erhält jetzt den Kodierungsbuchstaben mit den geringsten Kosten. Die zweithäufigste Kante erhält das zweitgünstigste Symbol usw. Dadurch wird angestrebt, dass teure Kodierungszeichen, also Perlen mit großem Durchmesser möglichst selten verwendet werden (in Pfaden mit seltenen Symbolen). So werden günstige Zeichen möglichst früh im Baum platziert, sodass sie häufiger vorkommen und damit mehr zur Gesamtkodierung beitragen können.

Diese lokale Regel zur Zuordnung führt nicht zu einer global optimalen Lösung, aber sie verteilt die teuren Kosten möglichst kosteneffizient in dem bestehenden Baum. Diese Heuristik ist leicht implementierbar, da diese nur eine kleine Anpassung der n -nären Huffman-Kodierung benötigt. Aus diesen Gründen wurde diese Strategie als erster Ansatz für die Lösung dieses Teilproblems gewählt. Sie dient als Baseline, an der weiterführende Verfahren verglichen werden können, die diese Strategie idealerweise übertreffen.

2.2.2 Umsetzung

Die Umsetzung dieser Strategie erfordert nur eine Anpassung der Teilschritte 4 und 5 des beschriebenen Algorithmus aus Kapitel 1. Die Schritte 1 bis 3 bleiben identisch (bis auf die Einlesung der Daten in Schritt 1 die minimal angepasst wird). Folgendes wird angepasst:

4. Traversierung mit greedy Kostenzuweisung

Die eigentliche Traversierung des Baums mit der rekursiven Tiefensuche bleibt identisch. Für die Zuweisung der Kosten, werden zunächst die Kinder nach ihrer Häufigkeit absteigend sortiert. Die verfügbaren Kodierungssymbole (in diesem Fall die Ziffern 0 bis $n - 1$) werden auch gemäß ihren zugehörigen Kosten aufsteigend sortiert. Mit einer Schleife über alle Kinder wird den Kanten zu den Teilbäumen nun jeweils das günstigste noch verfügbare Symbol zugewiesen, beginnend mit dem häufigsten Teilbaum. Für jedes Kind wird dieser Prozess rekursiv wiederholt, wobei der aktuelle Pfad (die bisher zugewiesenen Kodierungssymbole) jeweils an das entstehende Codewort angehängt wird.

5. Berechnung der Gesamtlänge der kodierten Nachricht

In diesem Schritt wird die Gesamtlänge der kodierten Nachricht bestimmt. Im Unterschied zur klassischen Huffman-Kodierung, bei der die Länge eines Codeworts einfach durch die Anzahl der Symbole bestimmt wird, müssen hier die individuellen Kosten der verwendeten Kodierungssymbole mit einberechnet werden. Die Gesamtlänge ergibt sich also nicht nur aus der Anzahl der Symbole im Codewort, sondern aus der Summe der Kosten aller Symbole, die zur Kodierung eines Zeichens verwendet werden.

2.2.3 Komplexitätsanalyse

Die Erklärung für die unveränderten Teilschritten bleibt wie in den Kapitel 1 und 2.2 gleich. Die Komplexität des Algorithmus hat sich wie folgt, geändert:

Schritt	Laufzeit	Speicherbedarf
Einlesen der Datei	$\mathcal{O}(L)$	$\mathcal{O}(L)$
Häufigkeitsanalyse	$\mathcal{O}(L)$	$\mathcal{O}(k)$
Aufbau des Huffman-Baums	$\mathcal{O}(k \log k)$	$\mathcal{O}(k)$
Generieren der Codetabelle	$\mathcal{O}(k \cdot n \log n)$	$\mathcal{O}(k \cdot n)$
Berechnung der Gesamtlänge	$\mathcal{O}(k)$	$\mathcal{O}(1)$
Ausgabe Codetabelle (mit Sortierung)	$\mathcal{O}(k \log k)$	$\mathcal{O}(k)$
Gesamt	$\mathcal{O}(L + k \log k)$	$\mathcal{O}(L + k)$

Table 2: Laufzeit- und Speicherkomplexität Teilaufgabe B Strategie 1

- **Codetabelle:** Dieser Schritt durchläuft jeden Knoten (insgesamt k Knoten) genau einmal mit DFS (Tiefensuche). Pro Knoten werden die Kinder und Kodierungszeichen sortiert, was in $\mathcal{O}(n \log n)$ ist. Daher beträgt die Laufzeit für diesen Schritt $\mathcal{O}(k \cdot n \log n)$.
- **Gesamtlänge:** Dieser Schritt iteriert über alle verschiedenen Symbole, die einen Code bekommen. Es wird über jedes Zeichen in Code iteriert und somit ist dieser Schritt in $\mathcal{O}(k \cdot L_{\max})$. L_{\max} ist hier die maximale Code-Länge (konstant), daher $\mathcal{O}(k)$.

2.2.4 Beispiele

Hier die Ausgaben des Programmes zu den Beispielen auf der BwInf-Webseite.

Die gesamte Ausgabe ist in **Aufgabe1/Ausgaben/AusgabenBStrategie1.txt** zu finden.

1. schmuck1.txt

Codetabelle:

(Jede Ziffer steht für eine Perlenfarbe z.B. könnte '0' rot bedeuten und '1' blau)

```
{
  'e': 02 (Freq: 9, Länge: 3)
  't': 11 (Freq: 6, Länge: 2)
  '□': 20 (Freq: 5, Länge: 3)
  'r': 21 (Freq: 3, Länge: 3)
  'i': 001 (Freq: 3, Länge: 3)
  'n': 002 (Freq: 3, Länge: 4)
  'w': 000 (Freq: 3, Länge: 3)
  'B': 101 (Freq: 2, Länge: 3)
  'I': 100 (Freq: 2, Länge: 3)
  '"': 102 (Freq: 2, Länge: 4)
  'b': 121 (Freq: 2, Länge: 4)
  'f': 122 (Freq: 2, Länge: 5)
  's': 120 (Freq: 2, Länge: 4)
  'F': 222 (Freq: 1, Länge: 6)
  'd': 220 (Freq: 1, Länge: 5)
  'u': 221 (Freq: 1, Länge: 5)
  'D': 0120 (Freq: 1, Länge: 5)
  'N': 0121 (Freq: 1, Länge: 5)
  'W': 0110 (Freq: 1, Länge: 4)
  'a': 0122 (Freq: 1, Länge: 6)
  'h': 0112 (Freq: 1, Länge: 5)
  'k': 0100 (Freq: 1, Länge: 4)
  'm': 0101 (Freq: 1, Länge: 4)
  'o': 0102 (Freq: 1, Länge: 5)
  'ü': 0111 (Freq: 1, Länge: 4)
}
```

Gesamtlänge der Botschaft 197 (in mm) bzw. 19.7cm


```

'i': 0101 (Freq: 1, Länge: 12)
'j': 0100 (Freq: 1, Länge: 8)
'k': 1000 (Freq: 1, Länge: 8)
'l': 1010 (Freq: 1, Länge: 12)
'm': 0110 (Freq: 1, Länge: 12)
'n': 0001 (Freq: 1, Länge: 8)
}

```

Gesamtlänge der Botschaft 154 (in mm) bzw. 15.4cm

Kodierte Nachricht: 000001111111011110001000111001010101001000101001100001

5. schmuck5.txt

Codetabelle:

(Jede Ziffer steht für eine Perlenfarbe z.B. könnte '0' rot bedeuten und '1' blau)

```

{
  '□': 2 (Freq: 151, Länge: 2)
  'e': 3 (Freq: 110, Länge: 3)
  't': 4 (Freq: 71, Länge: 4)
  'i': 5 (Freq: 67, Länge: 5)
  'o': 00 (Freq: 64, Länge: 2)
  's': 01 (Freq: 61, Länge: 2)
  'a': 02 (Freq: 58, Länge: 3)
  'n': 03 (Freq: 56, Länge: 4)
  'r': 04 (Freq: 51, Länge: 5)
  'c': 05 (Freq: 44, Länge: 6)
  'd': 06 (Freq: 37, Länge: 7)
  'l': 10 (Freq: 33, Länge: 2)
  'm': 11 (Freq: 27, Länge: 2)
  'h': 12 (Freq: 26, Länge: 3)
  'u': 14 (Freq: 25, Länge: 5)
  'f': 16 (Freq: 20, Länge: 7)
  'p': 15 (Freq: 20, Länge: 6)
  'b': 60 (Freq: 16, Länge: 7)
  'y': 61 (Freq: 13, Länge: 7)
  'g': 62 (Freq: 11, Länge: 8)
  '·': 63 (Freq: 8, Länge: 9)
  'q': 66 (Freq: 5, Länge: 12)
  ',': 130 (Freq: 5, Länge: 5)
  'v': 131 (Freq: 5, Länge: 5)
  'x': 132 (Freq: 5, Länge: 6)
  'w': 133 (Freq: 4, Länge: 7)
  'F': 134 (Freq: 3, Länge: 8)
  'T': 135 (Freq: 3, Länge: 9)
  'A': 650 (Freq: 1, Länge: 12)
  'G': 644 (Freq: 1, Länge: 14)
  'H': 651 (Freq: 1, Länge: 12)
  'S': 640 (Freq: 1, Länge: 11)
  '": 645 (Freq: 1, Länge: 15)
  'j': 652 (Freq: 1, Länge: 13)
  '-': 643 (Freq: 1, Länge: 13)
  '1': 646 (Freq: 1, Länge: 16)
  '2': 136 (Freq: 1, Länge: 10)
  '5': 653 (Freq: 1, Länge: 14)
  '9': 654 (Freq: 1, Länge: 15)
  'z': 641 (Freq: 1, Länge: 11)
  ';': 642 (Freq: 1, Länge: 12)
}

```

Gesamtlänge der Botschaft 4010 (in mm) bzw. 401.0cm

Kodierte Nachricht:

```
6401411110204612135125012150215304262513130120221134120006216000420500
030140414054503622115035111411643043061403060203056121504316513220500063012160004241232623
033040210206501050434320300501310301012051202030331021335412001442050003014040250340163213
512320500014012001620500063210344304012033306203004260323661402101302020306241232016111600
010012303050006306202043203004202010114113062400260323661402101061215040060026010363265020
100101445000321202062150431315001401106126033032625131303260612651141616110203250326466546
531362160004241232011530550210205020132503213312505122021010205000632103443040120204320016
236614021020500014632135123215043013034206313131000151130342501202106236004025056321345040
141302014041405414043216140305450003012020432063165033061302503243041101200162133125051220
330530101020461202030620114161650553034205000306545000301216000424123231325014303053200162
150431651322050006301211026126032014024306632134040011241230132050003065450003011302105033
020425033661402105453012020432063045131306213312505122110261260321401306240020512020402054
304564132150431651322050006301632644001100046164501250343623042150400620402111150362202106
200045412112501241230321401306240020500030140414054200154511141120500063012011460652305424
002412301325033661402105453016422020323103620203420500116050302400045021020215150400020512
240020060402503202201404505410612050011151440245000302102313215304530305325012150430130343
062400206311000301404024324123215040205450502605105461200162412321134120006632134503021010
611302010011320206065450003021020500065036221504006010311012020432065010514010130620203062
022150400601031120016205100201015165050245000325012404302430663
```

Dieses Ergebnis (4010) ist ca. 26.82% schlechter als der Vergleichswert (3162) von der BwInf Webseite, daher ist hier noch viel Platz für Verbesserung.

6. schmuck6.txt

Ich habe es nicht geschafft, dass Unicodezeichen hier in einem verbatim in latex angezeigt werden, daher sind die Zeichen leer. In der Textdatei mit den gesamten Ausgaben, sind diese Zeichen sichtbar.

Codetabelle:

(Jede Ziffer steht für eine Perlenfarbe z.B. könnte '0' rot bedeuten und '1' blau)

```
{
  "": 010 (Freq: 3, Länge: 4)
  "": 011 (Freq: 2, Länge: 5)
  "": 012 (Freq: 2, Länge: 6)
  "": 022 (Freq: 2, Länge: 7)
  "": 020 (Freq: 2, Länge: 5)
  "": 211 (Freq: 1, Länge: 7)
  "": 212 (Freq: 1, Länge: 8)
  "": 222 (Freq: 1, Länge: 9)
  "": 220 (Freq: 1, Länge: 7)
  "": 200 (Freq: 1, Länge: 5)
  "": 202 (Freq: 1, Länge: 7)
  "": 110 (Freq: 1, Länge: 5)
  "": 112 (Freq: 1, Länge: 7)
  "": 122 (Freq: 1, Länge: 8)
  "": 101 (Freq: 1, Länge: 5)
  "": 102 (Freq: 1, Länge: 6)
  "": 100 (Freq: 1, Länge: 4)
  "": 221 (Freq: 1, Länge: 8)
  "": 201 (Freq: 1, Länge: 6)
  "": 111 (Freq: 1, Länge: 6)
  "": 120 (Freq: 1, Länge: 6)
  "": 121 (Freq: 1, Länge: 7)
  "": 210 (Freq: 1, Länge: 6)
  "": 0210 (Freq: 1, Länge: 7)
```

```

"": 0002 (Freq: 1, Länge: 6)
"": 0021 (Freq: 1, Länge: 7)
"": 0011 (Freq: 1, Länge: 6)
"": 0000 (Freq: 1, Länge: 4)
"": 0001 (Freq: 1, Länge: 5)
"": 0022 (Freq: 1, Länge: 8)
"": 0020 (Freq: 1, Länge: 6)
"": 0012 (Freq: 1, Länge: 7)
"": 0010 (Freq: 1, Länge: 5)
"": 0211 (Freq: 1, Länge: 8)
}

```

Gesamtlänge der Botschaft 244 (in mm) bzw. 24.4cm

Kodierte Nachricht:

```

1011112122010002211010021112222120201011200001000010220012001202100201021100001
1200011011222012002202212102202001020000202100021011

```

7. schmuck7.txt

Codetabelle:

(Jede Ziffer steht für eine Perlenfarbe z.B. könnte '0' rot bedeuten und '1' blau)

```

{
  '□': 1 (Freq: 13488, Länge: 1)
  'e': 2 (Freq: 11480, Länge: 1)
  'n': 4 (Freq: 7761, Länge: 1)
  'i': 5 (Freq: 5018, Länge: 1)
  'r': 6 (Freq: 4011, Länge: 1)
  's': 7 (Freq: 3507, Länge: 2)
  'a': 8 (Freq: 3307, Länge: 3)
  'd': 9 (Freq: 3272, Länge: 4)
  'h': 00 (Freq: 3213, Länge: 2)
  't': 01 (Freq: 3174, Länge: 2)
  'u': 03 (Freq: 2609, Länge: 2)
  'l': 04 (Freq: 2448, Länge: 2)
  'c': 05 (Freq: 1991, Länge: 2)
  'g': 07 (Freq: 1665, Länge: 3)
  'm': 08 (Freq: 1521, Länge: 4)
  'o': 09 (Freq: 1304, Länge: 5)
  'b': 30 (Freq: 1141, Länge: 2)
  ',': 31 (Freq: 1077, Länge: 2)
  'f': 32 (Freq: 1000, Länge: 2)
  'w': 33 (Freq: 941, Länge: 2)
  '.': 34 (Freq: 831, Länge: 2)
  'k': 35 (Freq: 798, Länge: 2)
  'z': 37 (Freq: 631, Länge: 3)
  'S': 38 (Freq: 498, Länge: 4)
  'ä': 39 (Freq: 455, Länge: 5)
  'ü': 020 (Freq: 434, Länge: 3)
  'ö': 021 (Freq: 399, Länge: 3)
  'v': 022 (Freq: 361, Länge: 3)
  'F': 024 (Freq: 300, Länge: 3)
  'p': 023 (Freq: 300, Länge: 3)
  'ß': 025 (Freq: 278, Länge: 3)
  'D': 026 (Freq: 277, Länge: 3)
  'E': 027 (Freq: 243, Länge: 4)
  'V': 028 (Freq: 242, Länge: 5)
  'W': 060 (Freq: 231, Länge: 3)
  'N': 061 (Freq: 218, Länge: 3)

```

```

'K': 062 (Freq: 206, Länge: 3)
'B': 063 (Freq: 193, Länge: 3)
'A': 065 (Freq: 159, Länge: 3)
'M': 064 (Freq: 159, Länge: 3)
'H': 066 (Freq: 152, Länge: 3)
'I': 067 (Freq: 134, Länge: 4)
'L': 068 (Freq: 126, Länge: 5)
'R': 069 (Freq: 115, Länge: 6)
'G': 360 (Freq: 106, Länge: 3)
'T': 361 (Freq: 102, Länge: 3)
'Z': 363 (Freq: 79, Länge: 3)
'j': 364 (Freq: 72, Länge: 3)
'J': 365 (Freq: 68, Länge: 3)
'-' : 366 (Freq: 66, Länge: 3)
';' : 367 (Freq: 37, Länge: 4)
'(' : 368 (Freq: 32, Länge: 5)
')' : 369 (Freq: 32, Länge: 6)
':' : 0290 (Freq: 28, Länge: 7)
'_' : 0291 (Freq: 28, Länge: 7)
'O' : 0292 (Freq: 27, Länge: 7)
'U' : 0293 (Freq: 25, Länge: 7)
'[' : 0294 (Freq: 24, Länge: 7)
']' : 0295 (Freq: 24, Länge: 7)
'“' : 0296 (Freq: 21, Länge: 7)
',,' : 0297 (Freq: 21, Länge: 8)
'P' : 0298 (Freq: 20, Länge: 9)
'1' : 3620 (Freq: 16, Länge: 4)
'4' : 3621 (Freq: 13, Länge: 4)
'3' : 3622 (Freq: 9, Länge: 4)
'?' : 3623 (Freq: 8, Länge: 4)
'!' : 3625 (Freq: 7, Länge: 4)
'2' : 3626 (Freq: 7, Länge: 4)
'5' : 3624 (Freq: 7, Länge: 4)
'6' : 3627 (Freq: 6, Länge: 5)
'O' : 3628 (Freq: 5, Länge: 6)
'Ä' : 3629 (Freq: 3, Länge: 7)
'8' : 02991 (Freq: 3, Länge: 11)
'q' : 02990 (Freq: 3, Länge: 11)
''' : 02995 (Freq: 2, Länge: 11)
'7' : 02992 (Freq: 2, Länge: 11)
'9' : 02994 (Freq: 2, Länge: 11)
'Q' : 02993 (Freq: 2, Länge: 11)
'C' : 02996 (Freq: 1, Länge: 11)
'Ü' : 02997 (Freq: 1, Länge: 12)
'x' : 02998 (Freq: 1, Länge: 13)
'y' : 02999 (Freq: 1, Länge: 14)
}

```

Gesamtlänge der Botschaft 153144 (in mm) bzw. 15314.4cm

Kodierte Nachricht:

0650371920810682302410347262610280210720434106823501509413620341063235844...

8. schmuck8.txt

Ich habe es nicht geschafft, dass Unicodezeichen hier in einem verbatim in latex angezeigt werden, daher sind die Zeichen leer. In der Textdatei mit den gesamten Ausgaben, sind diese Zeichen sichtbar.

Codetabelle:

(Jede Ziffer steht für eine Perlenfarbe z.B. könnte '0' rot bedeuten und '1' blau)

```
{
  "": 04 (Freq: 33, Länge: 4)
  "": 10 (Freq: 27, Länge: 2)
  "": 42 (Freq: 13, Länge: 5)
  "": 43 (Freq: 13, Länge: 5)
  "": 44 (Freq: 12, Länge: 6)
  "": 000 (Freq: 11, Länge: 3)
  "": 001 (Freq: 11, Länge: 3)
  "": 002 (Freq: 10, Länge: 4)
  "": 011 (Freq: 10, Länge: 3)
  "": 024 (Freq: 9, Länge: 6)
  "": 032 (Freq: 7, Länge: 5)
  "": 031 (Freq: 7, Länge: 4)

  ...

  "": 1344 (Freq: 1, Länge: 9)
  "": 1310 (Freq: 1, Länge: 5)
  "": 1233 (Freq: 1, Länge: 7)
  "": 2001 (Freq: 1, Länge: 5)
  "": 2002 (Freq: 1, Länge: 6)
  "": 2033 (Freq: 1, Länge: 7)
  "": 2032 (Freq: 1, Länge: 7)
  "": 2030 (Freq: 1, Länge: 6)
  "": 2300 (Freq: 1, Länge: 6)
  "": 2302 (Freq: 1, Länge: 7)
  "": 2234 (Freq: 1, Länge: 9)
  "": 2233 (Freq: 1, Länge: 8)
  "": 1301 (Freq: 1, Länge: 5)
}
```

Gesamtlänge der Botschaft 3615 (in mm) bzw. 361.5cm

Kodierte Nachricht:

122020432424344202411004411014301210220040140240012110101121300341141334412...

9. schmuck9.txt

Ich habe es nicht geschafft, dass Unicodezeichen hier in einem verbatim in latex angezeigt werden, daher sind die Zeichen leer. In der Textdatei mit den gesamten Ausgaben, sind diese Zeichen sichtbar.

Codetabelle:

(Jede Ziffer steht für eine Perlenfarbe z.B. könnte '0' rot bedeuten und '1' blau)

```
{
  "": 30 (Freq: 173, Länge: 5)
  "": 33 (Freq: 139, Länge: 8)
  "": 000 (Freq: 138, Länge: 3)
  "": 010 (Freq: 126, Länge: 4)
  "": 011 (Freq: 123, Länge: 5)
  "": 013 (Freq: 119, Länge: 7)
  "": 021 (Freq: 112, Länge: 6)
  "": 022 (Freq: 111, Länge: 7)
  "": 023 (Freq: 108, Länge: 8)
  "": 031 (Freq: 105, Länge: 7)
  "": 100 (Freq: 89, Länge: 4)
  "": 102 (Freq: 83, Länge: 6)
  "": 103 (Freq: 81, Länge: 7)
}
```

```

...

"": 132110 (Freq: 1, Länge: 14)
"": 200302 (Freq: 1, Länge: 13)
"": 132112 (Freq: 1, Länge: 16)
"": 131021 (Freq: 1, Länge: 14)
"": 131233 (Freq: 1, Länge: 19)
"": 131022 (Freq: 1, Länge: 15)
"": 210120 (Freq: 1, Länge: 12)
"": 200023 (Freq: 1, Länge: 13)
"": 210131 (Freq: 1, Länge: 14)
"": 0022200 (Freq: 1, Länge: 13)
"": 0022201 (Freq: 1, Länge: 14)
}

```

Gesamtlänge der Botschaft 41056 (in mm) bzw. 4105.6cm

Kodierte Nachricht:

2023112003202011300230203203230300200220101020323030002300031001130231231112...

Dieses Ergebnis (41056) ist ca. 12.18% schlechter als der Vergleichswert (36597) von der BwInf Webseite, daher ist hier noch etwas Platz für Verbesserung.

2.2.5 Quellcode

Wichtige Teile des Quellcodes:

4. Erzeugen der Codetabelle mit greedy Heuristik

```

1 // 4. Generate Huffman codes with cost-aware digit assignment
private static void generateCodesCostAware(Node node, String currentCode, Map<Character,
    String> codeTable,
3     List<Integer> costs) {
    // Base case
5     if (node == null) {
        return;
7     }

9     // If it is a leaf, it represents a character, then assign a code
    if (node.isLeaf()) {
11         if (node.character != null) {
            codeTable.put(node.character, currentCode.isEmpty() ? "0" : currentCode);
13         }
        // Leaf is reached, stop recursion
15         return;
    }

17     List<Node> children = node.children;

19     // 1. Sort children by frequency - Descending (made copy to not modify the main
    // list, not sure if needed)
21     List<Node> sortedChildren = new ArrayList<>(children);
    sortedChildren.sort(Comparator.comparingLong(Node::getFrequency).reversed());

23     // 2. Prepare digits sorted by cost - Ascending
    // DigitCost is a wrapper to map each digit with its corresponding cost
25     List<DigitCost> digitCosts = new ArrayList<>();

27     for (int i = 0; i < costs.size(); i++) {
        digitCosts.add(new DigitCost(i, costs.get(i)));
31     }

    // Sort by cost ascending, for this input not needed as digits are already sorted
33     Collections.sort(digitCosts);

35     // 3. Assign cheapest digits to most frequent children
    for (int i = 0; i < sortedChildren.size(); i++) {

```

```

37     Node child = sortedChildren.get(i);
    int assignedDigit = digitCosts.get(i).digit; // i-th cheapest digit
39     generateCodesCostAware(child, currentCode + assignedDigit, codeTable, costs);
    }
41 }

```

5. Berechnung der Gesamtlänge

```

1 // 5. Calculate total cost of encoded message
private static long calculateTotalCost(Map<Character, String> codeTable, Map<Character,
    Long> frequencyMap,
3     List<Integer> costs) {
    long totalCost = 0;
5
6     // Iterate over each character
7     for (Map.Entry<Character, Long> entry : frequencyMap.entrySet()) {
        char character = entry.getKey();
9         long frequency = entry.getValue();
        String code = codeTable.get(character);
11
12         long costOfCode = 0;
13         for (char digitChar : code.toCharArray()) {
            int digit = Character.getNumericValue(digitChar);
15             costOfCode += costs.get(digit);
        }
17         totalCost += frequency * costOfCode;
    }
19     return totalCost;
}

```

2.3 Strategie 2: Modifizierung Golin/Li Algorithmus

2.3.1 Kernidee

Da die erste implementierte Strategie als Referenz verwendet wird und die berechneten Gesamtlängen der kodierten Nachrichten nicht nahe genug an den Werten der BwInf Webseite liegen, wird eine weiterer Algorithmus erkundet. Das Problem einen Text nahezu optimal präfixfrei zu kodieren, wenn die Symbole zur Kodierung unterschiedliche Kosten aufweisen, ist nicht trivial. Der Algorithmus von Golin und Li [2] bietet eine effiziente $\mathcal{O}(n \log n)$ Lösung (mit n als Anzahl der Quellsymbole) mit einer bewiesenen guten Fehlerschranke gegenüber dem Optimum, die besser als der Ansatz aus Kapitel 2.2 sein sollte. Daher wird im Folgenden ein Algorithmus basierend auf [2, Fig 6. und Kapitel 4] implementiert, der die Kernprinzipien des Golin/Li-Algorithmus anwendet, um einen solchen Präfixcode zu finden. Der umgesetzte Algorithmus vereinfacht allerdings Teile aus dem Paper etwas, da diese sehr komplex ist. Daher kann die bewiesene Fehlerschranke zu dem Optimum nicht mehr garantiert werden. Dennoch sollte der Algorithmus bessere Resultate bringen.

Zum Verständnis des Algorithmus werden folgende zwei Hauptsatzsätze definiert:

1. Eine Menge von n Quellsymbolen, jeweils mit einer zugehörigen Auftrittswahrscheinlichkeit $0 < p < 1$, basierend auf deren Häufigkeit im Text. Diese Symbole werden absteigend nach ihrer Wahrscheinlichkeit sortiert ($p_1 \geq p_2 \geq \dots \geq p_n$).
2. Eine Menge von t Kodierungsbuchstaben (Zielalphabet, also Perlenfarben bzw. Ziffern), jeweils mit positiven Kosten c_m (also Durchmesser der Perle). Diese werden aufsteigend nach ihren Kosten sortiert ($c_1 \leq c_2 \leq \dots \leq c_t$).

Ein wichtiger Aspekt zur Lösung des Problems ist, die unterschiedlichen Kosten der verfügbaren Kodierungsbuchstaben fair den Quellsymbolen zuzuordnen, welche unterschiedlich oft auftreten. Anstatt wie der klassische Huffman-Algorithmus das Zusammenfügen der unwahrscheinlichsten Symbole und dann eine Zuordnung mit Kodierungsbuchstaben, wählt Golin/Li einen globaleren Ansatz, der auf eine intelligente Aufteilung des Wahrscheinlichkeitsraums basiert.

Die Kernidee des Algorithmus ist eine rekursive Aufteilung der Quellsymbole in sogenannte "Bins" bzw. Gruppen. Die Zuweisung des ersten Kodierungsbuchstabens zu verschiedenen Gruppen von Quellsymbolen

soll dabei nicht willkürlich, sondern kostenbewusst gemacht werden. Man möchte erreichen, dass Kodierungsbuchstaben mit *geringen* Kosten tendenziell den Gruppen von Quellsymbolen zugeordnet werden, die zusammen eine höhere Gesamtwahrscheinlichkeit aufweisen. Dies ist intuitiv.

Um dieses Ausbalancieren zu erreichen, betrachtet der Algorithmus nicht die einzelnen Symbole isoliert, sondern ihre Verteilung im **kumulativen Wahrscheinlichkeitsraum**. Man kann sich vorstellen, dass alle Quellsymbole, sortiert nach ihrer Wahrscheinlichkeit p_m auf einem Intervall von 0 bis 1 angeordnet sind, wo die Länge des Abschnitts für Symbol i seiner Wahrscheinlichkeit p_m entspricht. Die Gesamtlänge dieses Intervalls ist 1.

Der Algorithmus zerlegt nun dieses Gesamtintervall (bzw. in rekursiven Schritten ein Teilintervall, einer bereits gebildeten Gruppe) in t Segmente, wo t die Anzahl der verfügbaren Kodierungsbuchstaben ist. Jedes Segment wird einem Kodierungsbuchstaben m zugeordnet und stellt ein Bin dar.

Nun ist das Entscheidende, wie groß diese Bins/Segmente gemacht werden. Hierfür wird die **charakteristische Wurzel c** benutzt. Sie ist gewissermaßen ein Skalierungsfaktor, der die Kosten c_m von jedem Kodierungsbuchstaben in ein "effektives Gewicht" (definiert als $2^{-c \cdot c_m}$) übersetzt. Dieses Gewicht repräsentiert den "fairen Anteil", den dieser Buchstabe in der Kodierung beiträgt. Die Breite des Bins für den Kodierungsbuchstaben m wird nun proportional zu diesem effektiven Gewicht festgelegt:

$$\text{Breite}(\text{Bin } m) = w \cdot (\text{Gesamtwahrscheinlichkeit der aktuellen Symbolgruppe}) \cdot 2^{-c \cdot c_m} \quad (3)$$

Diese charakteristische Wurzel c ist definiert als eindeutige positive reelle Zahl, die folgende Gleichung erfüllt:

$$\sum_{m=1}^t 2^{-c \cdot c_m} = 1 \quad (4)$$

mit t : Zahl der Kodierungssymbolen und c_m die Kosten des m -ten Symbols.

Diese Gleichung ist eine Verallgemeinerung der Kraft-McMillan-Ungleichung für den Fall ungleicher Kosten und ist eine notwendige Bedingung für die Existenz eines vollständigen Präfixcodes.

Aus der Definition von c folgt, dass die Summe dieser Gewichte 1 betragen muss und diese Tatsache ist auch mathematisch notwendig, um den gesamten Wahrscheinlichkeitsraum der Quellsymbole abzudecken. In dem Fall mit den Perlen heißt das konkret, dass eine Perle mit großem Durchmesser durch c ein kleines "Gewicht", also einen **kleineren Anteil** und eine kleine Perle ein großes Gewicht, also einen **größeren Anteil** am Wahrscheinlichkeitsintervall bekommt.

Nachdem das Wahrscheinlichkeitsintervall, mit den gewichteten Kosten im Blick, aufgeteilt wurde, werden die einzelnen Quellsymbole diesen Bins zugeordnet. Dies geschieht mit einer Heuristik. Betrachtet wird die Quellsymbole $1, 2, \dots, k$, sortiert nach absteigender Wahrscheinlichkeit. Sei

- p_i : die **individuelle Auftrittswahrscheinlichkeit** des Symbols i .
- P_i : die **kumulative Wahrscheinlichkeit** der Symbole 1 bis i , also $P_i = p_1 + p_2 + \dots + p_i$. Außerdem ist $P_0 = 0$.

Für jedes Symbol i wird sein **Wahrscheinlichkeitsmittelpunkt** s_i innerhalb seines Abschnitts im kumulativen Intervall $[P_{i-1}, P_i]$ berechnet als:

$$s_i = P_{i-1} + \frac{p_i}{2} \quad (5)$$

Dieser Mittelpunkt s_i repräsentiert eine Position für das Symbol i im gesamten Wahrscheinlichkeitsraum $[0, 1)$. Das Symbol i wird dem Bin m zugewiesen, in dessen Intervall $[L_m, R_m)$ dieser Mittelpunkt s_i fällt. Dieser Prozess des Zuweisens von Symbolen an Bins wird **rekursiv** für jedes dieser Bins wiederholt, um den zweiten Kodierungsbuchstaben zu bestimmen usw. In jedem rekursiven Schritt wird das relevante Teilintervall der Wahrscheinlichkeit erneut nach dem gleichen Prinzip (also kosten-gewichtet mit c) aufgeteilt. Dadurch entsteht ein Codebaum von dem die Struktur die ungleichen Kosten **von Anfang an berücksichtigt**, im Gegensatz zu n -ärem Huffman. Daher sollte dieser Algorithmus bessere Ergebnisse liefern, die aber noch garantiert nicht optimal sind. Dieser Baum muss am Ende nicht mehr traversiert werden, da der Baum "top-down" (im Gegensatz zu Huffman) erstellt wird, und wenn der rekursive Aufruf zur Erstellung des Baums an ein "Blatt" (hier also wenn in einem Bin nur ein Symbol ist), wird der sich der Pfad bis dahin gemerkt und als Codewort des Symbols festgelegt.

Dieser Aufteilungsmechanismus funktioniert und ist der Kern dieser Strategie (2.3), weil er systematisch die **Wahrscheinlichkeiten der Quellsymbole mit den Kosten der Kodierungsbuchstaben verknüpft**. Die wahrscheinlicheren Symbole (die größere Abschnitte im kumulativen Intervall belegen) haben eine höhere Chance, in den breiteren Bins zu landen. Da die breiteren Bins durch die c -gewichtete Aufteilung den kostengünstigeren Kodierungsbuchstaben entsprechen, bekommen die häufigen Symbolgruppen tendenziell die "billigeren" Kodierungsbuchstaben.

Anmerkung: Die Mittelpunkt Heuristik kann auch zu suboptimalen Verteilungen führen, so dass z.B. leere Bins zwischen gefüllten Bins sind oder, dass alle Symbole in Bin eins sind. Das Golin/Li Paper definiert sogenannte "Left Shift" und "Right Shift" Operationen, um diese Verteilungen zu verbessern. Der Left Shift füllt leere Bins auf, indem Symbole aus den nachfolgenden Bins nach vorne verschoben werden. Dieser Prozess ist in dem Paper allerdings sehr komplex und wird in dieser Implementierung stark vereinfacht. Der Right Shift behandelt den seltenen Spezialfall, dass alle Symbole im ersten Bin landen, indem das letzte Symbol in den zweiten Bin verschoben wird. So wird eine übermäßige Nutzung des ersten Bins vermieden.

2.3.2 Umsetzung

Diese Implementierung folgt den Kernprinzipien des Algorithmus von Golin/Li [2, Fig. 6 und Kapitel 4], Kapitel IV, wobei die Logik des Left Shifts vereinfacht wurde:

Schritt 1 "Einlesung der Daten" und Schritt 2 "Häufigkeitsanalyse der Symbole im Text" aus Kapitel 1 und 2.2 bleiben gleich. Für kommende Berechnungen mit den Durchmessern der Perlen werden diese allerdings als Doubles gespeichert.

3. Berechnung der charakteristischen Wurzel c

Die Bestimmung der charakteristischen Wurzel c ist ein wichtiger Teilschritt, der für die Aufteilung in Bins benötigt wird. Um c numerisch zu berechnen, wird die Gleichung 4 gelöst, indem das Bisektionsverfahren verwendet wird. Das funktioniert, indem es schrittweise das Intervall $[0, 10]$ halbiert und jeweils entscheidet, ob die Nullstelle der Funktion $f(c) = \sum 2^{-c \cdot c_m} - 1$ im linken oder rechten Teilintervall liegt, bis eine gewisse Genauigkeit erreicht ist. Diese Methode funktioniert nur, wenn $c < 10$, da das das gewählte Startintervall ist.

4. Rekursive Codegenerierung

Für die Rekursion muss jeweils die linke Grenze (bezeichnet als l) und die rechte Grenze (bezeichnet als r) des betrachteten Intervalls bekannt sein.

0. Basisfall

Die Rekursion endet, wenn das betrachtete Teilintervall nur noch ein einziges Symbol enthält ($l == r$). Der bis dahin akkumulierte Präfix U (Pfad bis zum Bin) wird diesem Symbol als finales Codewort in der Codetabelle zugeordnet.

1. Symbolzuweisung zu Initial-Bins

Jedes Symbol i innerhalb der aktuellen Teilmenge (l bis r) wird basierend auf seinem Wahrscheinlichkeitsmittelpunkt, das mit der Gleichung 5 berechnet wird, zu dem Bin m zugeordnet. Die Indizes der Symbole werden in *initialBins* gesammelt.

2. Left Shift (Stark vereinfacht)

Anstatt der komplexen Shifting Operation aus dem Originalalgorithmus implementiert der Code einen vereinfachten Left Shift. Er iteriert durch die *initialBins*. Wenn ein Bin leer ist, wird versucht, ihn mit dem nächsten noch nicht zugewiesenen Symbol aus der sortierten Liste zu füllen. So wird die Idee, Lücken zu schließen, versucht zu bewahren.

3. Right Shift

Der spezifische Fall, dass alle Symbole im ersten Bin landen (`finalBins.size() == 1`), wird explizit überprüft. Wenn dies zutrifft und mehr als ein Symbol vorhanden ist, wird der Index des letzten Symbols aus dem ersten Bin entfernt und einem neu erstellten zweiten Bin hinzugefügt.

4. Rekursiver Aufruf

Schließlich wird für jeden nicht leeren Bin ein rekursiver Aufruf gestartet. Der Kodierungsbuchstabe

des Bins wird dabei an den aktuellen Präfix U angehängt, damit der Basisfall das Codewort festlegen kann. Der rekursive Aufruf erfolgt dann für die Teilmenge der Symbole in diesem Bin mit den angepassten Grenzen für das Betrachten des Intervalls.

Schritt 5 "Berechnung der Gesamtlänge des kodierten Texts" und Schritt 6 "Ausgabe der Codetabelle" aus Kapitel 1 und 2.2 bleiben gleich.

2.3.3 Komplexitätsanalyse

Nun wird die Komplexität der einzelnen Schritte des Algorithmus betrachtet, die Erklärungen für die unveränderten Teilschritten bleiben wie in den Kapitel 1 und 2.2 gleich. Dabei ist:

- L die Länge des Eingabetextes,
- k die Anzahl der verschiedenen Zeichen (eindeutige Quellsymbole),
- n die Anzahl der Kodierungsbuchstaben (Anzahl Perlenfarben).

Schritt	Laufzeit	Speicherbedarf
Einlesen der Datei	$\mathcal{O}(L)$	$\mathcal{O}(L)$
Häufigkeitsanalyse	$\mathcal{O}(L)$	$\mathcal{O}(k)$
Berechnung der charakteristischen Wurzel	$\mathcal{O}(n)$	$\mathcal{O}(1)$
Rekursive Codegenerierung	$\mathcal{O}(k \log k)$	$\mathcal{O}(k \log k + k + n)$
Berechnung der Gesamtlänge	$\mathcal{O}(k)$	$\mathcal{O}(1)$
Ausgabe Codetabelle (mit Sortierung)	$\mathcal{O}(k \log k)$	$\mathcal{O}(k)$
Gesamt	$\mathcal{O}(L + k \log k + n)$	$\mathcal{O}(L + k + n + k \log k)$

Table 3: Laufzeit- und Speicherkomplexität Teilaufgabe B mit Strategie 2

- **Berechnung der charakteristischen Wurzel c :** Bei jedem Aufruf der Funktion $f(c)$ muss die Summe $\sum_{i=1}^n 2^{-c \cdot c_m}$ berechnet werden. Dies braucht n Potenzierungs- und Additionsoperationen. Die Laufzeit für eine einzelne Auswertung von $f(c)$ ist daher $\mathcal{O}(n)$. Da dies 100-mal getan wird (Bisektionsverfahren 100-mal angewendet), gilt $\mathcal{O}(100 \cdot n) = \mathcal{O}(n)$.
- **Rekursive Codegenerierung:** Die rekursive Methode `generateCodesGolinLi()` wird $\mathcal{O}(k)$ mal aufgerufen. Die zeitaufwendigste Operation in jedem Aufruf ist die Zuweisung von k' Symbolen zu n Bins, was $\mathcal{O}(n \cdot k')$ braucht. Die Gesamtlaufzeit hängt von der Rekursionstiefe und die Balance des Codebaums ab. Für diese Implementierung mit vereinfachtem Shifting ergibt sich daher geschätzt eine Laufzeit zwischen $\mathcal{O}(n \cdot k \log k)$ (balancierter Baum, aufgrund Aufteilung), da n eine kleine Konstante ist: $\mathcal{O}(k \log k)$.

Insgesamt ist die Laufzeit dominiert durch die rekursive Struktur des Algorithmus und die optionale Sortierung für die Ausgabe der Codetabelle. Der Speicherbedarf (hier geschätzt) ist etwas größer als bei Strategie 1, dennoch nichts bemerkenswertes. Die tatsächliche Speicherkomplexität hängt stark von der Struktur des generierten Codes ab und der Tiefe des Rekursionsstacks.

Wenn die Liste mit n Kodierungsbuchstaben nicht sortiert wäre, wie in den Beispielen der BwInf Webseite, müsste diese noch sortiert werden und die Gesamtlaufzeit erhöht sich um $\mathcal{O}(n \log n)$. Daher erweist sich dieser Algorithmus auch bei größeren Texten als leistungsfähig und mit ungefähr derselben asymptotischen Laufzeit wie Strategie 1.

2.3.4 Beispiele

Hier die Ausgaben des Programmes zu den Beispielen auf der BwInf-Webseite.

Die gesamte Ausgabe ist in **Aufgabe1/Ausgaben/AusgabenBStrategie2.txt** zu finden.

1. schmuck1.txt


```

'n': 111 (Freq: 56, Länge: 3)
'r': 112 (Freq: 51, Länge: 4)
'c': 12 (Freq: 44, Länge: 3)
'd': 13 (Freq: 37, Länge: 4)
'l': 200 (Freq: 33, Länge: 4)
'm': 201 (Freq: 27, Länge: 4)
'h': 210 (Freq: 26, Länge: 4)
'u': 211 (Freq: 25, Länge: 4)
'f': 22 (Freq: 20, Länge: 4)
'p': 23 (Freq: 20, Länge: 5)
'b': 30 (Freq: 16, Länge: 4)
'y': 310 (Freq: 13, Länge: 5)
'g': 311 (Freq: 11, Länge: 5)
'.'': 312 (Freq: 8, Länge: 6)
',': 32 (Freq: 5, Länge: 5)
'q': 33 (Freq: 5, Länge: 6)
'v': 400 (Freq: 5, Länge: 6)
'x': 401 (Freq: 5, Länge: 6)
'w': 410 (Freq: 4, Länge: 6)
'T': 42 (Freq: 3, Länge: 6)
'F': 411 (Freq: 3, Länge: 6)
'A': 43 (Freq: 1, Länge: 7)
'G': 44 (Freq: 1, Länge: 8)
'2': 52 (Freq: 1, Länge: 7)
'5': 53 (Freq: 1, Länge: 8)
'9': 60 (Freq: 1, Länge: 7)
'z': 61 (Freq: 1, Länge: 7)
';': 62 (Freq: 1, Länge: 8)
'H': 500 (Freq: 1, Länge: 7)
'S': 501 (Freq: 1, Länge: 7)
'''': 502 (Freq: 1, Länge: 8)
'j': 510 (Freq: 1, Länge: 7)
'-'': 511 (Freq: 1, Länge: 7)
'1': 512 (Freq: 1, Länge: 8)
}

```

Gesamtlänge der Botschaft 3374 (in mm) bzw. 337.4cm

Kodierte Nachricht:

```

501211201201110112310004221002101002311023010112003110240001010100110002010100112101001
300221001120012100111101011112211120110211131100201021110220121120151111201013211111131
101111231000231120102202401001210013010101002210011200011210010003110101110101121102000
01302101121120100110100011110002101010200010101101001221011011111010200004100201121010
021101100121001111010111121100211101110131200422100100012100101011101001002200121001301
000200010011011010112101001110100101300111100011003001000010332111102003200110111130001
121001000101310201301002001010001011112100130101300110112010001111000110011010110121120
1010130001110000300100001033211110200200310002311121003011030200010312004300101100200211
011021001110021011013002311201040002100211101200310003001001011100311024000101110030310
005002112222201110111000211100512605352002210011200011210010001012301012021102000012110
101010000211100410210021221000110200200001210013010002000100110110101121010011011201000
100220001033211110200001210010101131200422100100023112010101010111011001301040001020010
023201010111011000210100110200311010301121100212312004110211210101132001010111122111201
121111201000222111111201102100111101001101120100013010220211101013320002111000110101122
011010010022004102100212210001110101201010110111011231000110111130010121122220212020101
110110012100111130201102100111101002210011200011210010000104010210101101011112010001002
200231120102202401001210013010101002011103100030010001010111100110101331200411112100201
000112100101010100012100111130201102100111101320020002111010110112000211101033211110200
020110201010100110112010001301011202400010130041021002122100020111031000300100021110101
013000111000012210110112110120110101120261010002311201022024010012100130101013120044100

```

```

201100112310502101000211101101031101011200231121003111121102012010211131100110200311100
112020112102010002101000112100101110021110101013000111000012100111101011112211120110010
023011022012112010012100130101010010121130510010120110001110000011210010101010000211101
033211110200020110201010162001101110001020001031111011101100121002013002111110011100112
021102000011023231121001101221000011100001003001111002111001100010101111202120112003100
012100201232110111100110210011111020000010401230101120201011112010000210100231120101010
101110110101300011100001301020110011110101111211001101000011210010002311211012011021211
030022000201131000100220001121001000201010011210100133120041102111110200200310320010110
020101000110131302011021001111102000012100130211131100231121003020001020110100110112010
001302101122111011010101300110111130011000231121003020001020100100220012200110101101022
202121100110210011100021010001111201011001101013312

```

Dieses Ergebnis (3374) ist ca. 6.7% schlechter als der Vergleichswert (3162) von der BwInf Webseite, also bereits eine großer Fortschritt im Verleich zu Strategie 1.

6. schmuck6.txt

Charakteristische Wurzel $c = 0.879146$

Codetabelle (Golin/Li):

```

{
  "": 0000 (Freq: 3, Länge: 4)
  "": 0001 (Freq: 2, Länge: 5)
  "": 0002 (Freq: 2, Länge: 6)
  "": 0010 (Freq: 2, Länge: 5)
  "": 0011 (Freq: 2, Länge: 6)
  "": 22 (Freq: 1, Länge: 6)
  "": 002 (Freq: 1, Länge: 5)
  "": 012 (Freq: 1, Länge: 6)
  "": 021 (Freq: 1, Länge: 6)
  "": 022 (Freq: 1, Länge: 7)
  "": 102 (Freq: 1, Länge: 6)
  "": 111 (Freq: 1, Länge: 6)
  "": 120 (Freq: 1, Länge: 6)
  "": 121 (Freq: 1, Länge: 7)
  "": 201 (Freq: 1, Länge: 6)
  "": 210 (Freq: 1, Länge: 6)
  "": 211 (Freq: 1, Länge: 7)
  "": 0101 (Freq: 1, Länge: 6)
  "": 0110 (Freq: 1, Länge: 6)
  "": 0111 (Freq: 1, Länge: 7)
  "": 0200 (Freq: 1, Länge: 6)
  "": 0201 (Freq: 1, Länge: 7)
  "": 1001 (Freq: 1, Länge: 6)
  "": 1002 (Freq: 1, Länge: 7)
  "": 1010 (Freq: 1, Länge: 6)
  "": 1011 (Freq: 1, Länge: 7)
  "": 1100 (Freq: 1, Länge: 6)
  "": 1101 (Freq: 1, Länge: 7)
  "": 2000 (Freq: 1, Länge: 6)
  "": 2001 (Freq: 1, Länge: 7)
  "": 01000 (Freq: 1, Länge: 6)
  "": 01001 (Freq: 1, Länge: 7)
  "": 10000 (Freq: 1, Länge: 6)
  "": 10001 (Freq: 1, Länge: 7)
}

```

Gesamtlänge der Botschaft 240 (in mm) bzw. 24.0cm

Kodierte Nachricht:

```

101012101001110101010100000002210001102020100000221001110020101200022001002001110

```

1102110022000100000001011000021110010210001000110000020012021101110001

7. schmuck7.txt

Charakteristische Wurzel $c = 2.840332$

Codetabelle (Golin/Li):

```
{
  '□': 0 (Freq: 13488, Länge: 1)
  'e': 1 (Freq: 11480, Länge: 1)
  'n': 2 (Freq: 7761, Länge: 1)
  'i': 30 (Freq: 5018, Länge: 2)
  'r': 31 (Freq: 4011, Länge: 2)
  's': 32 (Freq: 3507, Länge: 2)
  'a': 40 (Freq: 3307, Länge: 2)
  'd': 41 (Freq: 3272, Länge: 2)
  'h': 42 (Freq: 3213, Länge: 2)
  't': 43 (Freq: 3174, Länge: 2)
  'u': 50 (Freq: 2609, Länge: 2)
  'l': 51 (Freq: 2448, Länge: 2)
  'c': 52 (Freq: 1991, Länge: 2)
  'g': 53 (Freq: 1665, Länge: 2)
  'm': 54 (Freq: 1521, Länge: 2)
  'o': 55 (Freq: 1304, Länge: 2)
  'b': 60 (Freq: 1141, Länge: 2)
  ',': 610 (Freq: 1077, Länge: 3)
  'f': 611 (Freq: 1000, Länge: 3)
  'w': 62 (Freq: 941, Länge: 2)
  '.': 630 (Freq: 831, Länge: 3)
  'k': 631 (Freq: 798, Länge: 3)
  'z': 640 (Freq: 631, Länge: 3)
  'S': 641 (Freq: 498, Länge: 3)
  'ä': 642 (Freq: 455, Länge: 3)
  'ü': 650 (Freq: 434, Länge: 3)
  'ö': 651 (Freq: 399, Länge: 3)
  'v': 652 (Freq: 361, Länge: 3)
  'F': 653 (Freq: 300, Länge: 3)
  'p': 654 (Freq: 300, Länge: 3)
  'ß': 660 (Freq: 278, Länge: 3)
  'D': 661 (Freq: 277, Länge: 3)
  'E': 662 (Freq: 243, Länge: 3)
  'V': 663 (Freq: 242, Länge: 3)
  'W': 664 (Freq: 231, Länge: 3)
  'N': 665 (Freq: 218, Länge: 3)
  'K': 67 (Freq: 206, Länge: 3)
  'B': 70 (Freq: 193, Länge: 3)
  'A': 710 (Freq: 159, Länge: 4)
  'M': 711 (Freq: 159, Länge: 4)
  'H': 72 (Freq: 152, Länge: 3)
  'I': 730 (Freq: 134, Länge: 4)
  'L': 731 (Freq: 126, Länge: 4)
  'R': 740 (Freq: 115, Länge: 4)
  'G': 741 (Freq: 106, Länge: 4)
  'T': 750 (Freq: 102, Länge: 4)
  'Z': 751 (Freq: 79, Länge: 4)
  'j': 752 (Freq: 72, Länge: 4)
  'J': 760 (Freq: 68, Länge: 4)
  '-': 761 (Freq: 66, Länge: 4)
  ';': 762 (Freq: 37, Länge: 4)
```

```

'(': 763 (Freq: 32, Länge: 4)
')': 764 (Freq: 32, Länge: 4)
'_': 77 (Freq: 28, Länge: 4)
':': 765 (Freq: 28, Länge: 4)
'0': 80 (Freq: 27, Länge: 4)
'U': 81 (Freq: 25, Länge: 4)
'[': 820 (Freq: 24, Länge: 5)
']': 821 (Freq: 24, Länge: 5)
'“': 83 (Freq: 21, Länge: 4)
',,: 840 (Freq: 21, Länge: 5)
'P': 841 (Freq: 20, Länge: 5)
'1': 850 (Freq: 16, Länge: 5)
'4': 851 (Freq: 13, Länge: 5)
'3': 860 (Freq: 9, Länge: 5)
'?': 861 (Freq: 8, Länge: 5)
'5': 87 (Freq: 7, Länge: 5)
'!': 862 (Freq: 7, Länge: 5)
'2': 863 (Freq: 7, Länge: 5)
'6': 90 (Freq: 6, Länge: 5)
'0': 91 (Freq: 5, Länge: 5)
'8': 92 (Freq: 3, Länge: 5)
'Ä': 93 (Freq: 3, Länge: 5)
'q': 940 (Freq: 3, Länge: 6)
'''': 941 (Freq: 2, Länge: 6)
'7': 950 (Freq: 2, Länge: 6)
'9': 951 (Freq: 2, Länge: 6)
'Q': 960 (Freq: 2, Länge: 6)
'y': 97 (Freq: 1, Länge: 6)
'C': 961 (Freq: 1, Länge: 6)
'Ö': 962 (Freq: 1, Länge: 6)
'x': 963 (Freq: 1, Länge: 6)
}

```

Gesamtlänge der Botschaft 144964 (in mm) bzw. 14496.4cm

Kodierte Nachricht:

71050320411540731160120502321311310663651531516300731163143305520850630070163140224...

8. schmuck8.txt

Charakteristische Wurzel $c = 1.501402$

Codetabelle (Golin/Li):

```

{
  "": 000 (Freq: 33, Länge: 3)
  "": 001 (Freq: 27, Länge: 3)
  "": 002 (Freq: 13, Länge: 4)
  "": 0100 (Freq: 13, Länge: 4)
  "": 0101 (Freq: 12, Länge: 4)
  "": 0110 (Freq: 11, Länge: 4)
  "": 0111 (Freq: 11, Länge: 4)
  "": 012 (Freq: 10, Länge: 4)
  "": 0112 (Freq: 10, Länge: 5)
  "": 013 (Freq: 9, Länge: 4)
  "": 014 (Freq: 7, Länge: 5)
  "": 0200 (Freq: 7, Länge: 5)
  "": 0201 (Freq: 7, Länge: 5)
  "": 021 (Freq: 6, Länge: 4)
  "": 210010 (Freq: 1, Länge: 7)
  "": 210011 (Freq: 1, Länge: 7)
}

```

```

": 211010 (Freq: 1, Länge: 7)
": 211011 (Freq: 1, Länge: 7)
": 300010 (Freq: 1, Länge: 7)
": 300011 (Freq: 1, Länge: 7)
": 301010 (Freq: 1, Länge: 7)
": 301011 (Freq: 1, Länge: 7)
": 310010 (Freq: 1, Länge: 7)
": 310011 (Freq: 1, Länge: 7)
": 311010 (Freq: 1, Länge: 7)
": 311011 (Freq: 1, Länge: 7)
}

```

Gesamtlänge der Botschaft 3433 (in mm) bzw. 343.3cm

Kodierte Nachricht:

410222221211022200310220001020111411200122100011303101030011121101313011403112100210...

9. schmuck9.txt

Charakteristische Wurzel $c = 0.946777$

Codetabelle (Golin/Li):

```

{
  ": 00000 (Freq: 173, Länge: 5)
  ": 00001 (Freq: 139, Länge: 6)
  ": 00010 (Freq: 138, Länge: 6)
  ": 00011 (Freq: 126, Länge: 7)
  ": 0002 (Freq: 123, Länge: 6)
  ": 00100 (Freq: 119, Länge: 6)
  ": 00101 (Freq: 112, Länge: 7)
  ": 0011 (Freq: 111, Länge: 6)
  ": 002 (Freq: 108, Länge: 5)
  ": 003 (Freq: 105, Länge: 6)
  ": 01000 (Freq: 89, Länge: 6)
  ": 01001 (Freq: 83, Länge: 7)
  ": 32000001 (Freq: 1, Länge: 14)
  ": 300001000 (Freq: 1, Länge: 13)
  ": 300001001 (Freq: 1, Länge: 14)
  ": 300010000 (Freq: 1, Länge: 13)
  ": 300010001 (Freq: 1, Länge: 14)
  ": 300100000 (Freq: 1, Länge: 13)
  ": 300100001 (Freq: 1, Länge: 14)
  ": 301000000 (Freq: 1, Länge: 13)
  ": 301000001 (Freq: 1, Länge: 14)
  ": 310000000 (Freq: 1, Länge: 13)
  ": 310000001 (Freq: 1, Länge: 14)
}

```

Gesamtlänge der Botschaft 38516 (in mm) bzw. 3851.6cm

Kodierte Nachricht:

31130312010201031200113100032100021210231001113201020000012001123000010111002102000101...

Dieses Ergebnis (38516) ist ca. 5.2% schlechter als der Vergleichswert (36597) von der BwInf Webseite, daher eigentlich schon akzeptabel.

2.3.5 Quellcode

Wichtige Teile des Quellcodes:

Berechnung der Charakteristische Wurzel c

```

// 3. Find Characteristic root c for equation:  $\sum(2^{(-c*d_i)}) = 1$ 
private static double findCharacteristicRoot(double[] diameters) {
    // Define function  $f(c) = \sum(2^{(-c*d_i)}) - 1$ 
    Function<Double, Double> f = (c) -> {
        double sum = 0.0;
        for (double d : diameters) {
            sum += Math.pow(2.0, -c * d);
        }
        return sum - 1.0;
    };

    // Find c, numeric approach with bisection
    double low = 0.0;
    double high = 10.0; // Assumption: c not too big
    // Check limits
    if (f.apply(TOLERANCE) < 0)
        return Double.NaN; // No positiv root possible

    // I randomly chose 100 iterations, probably good enough
    for (int i = 0; i < 100; i++) {
        double mid = low + (high - low) / 2.0;
        double f_mid = f.apply(mid);

        if (Math.abs(f_mid) < TOLERANCE) {
            return mid;
        } else if (f_mid > 0) { // Root on the right
            low = mid;
        } else { // Root on the left
            high = mid;
        }
    }
    // Return best value
    return low + (high - low) / 2.0;
}

```

Rekursive Codegenerierung

```

// 4. Recursive method for code generation with pseudocode from Golin/Li as basis
// (Fig.6 in paper)
// U is the current prefix code
private static void generateCodesGolinLi(List<Symbol> symbols, int l, int r,
    String U, Map<Character, String> codeTable,
    List<Perle> sortedDiameters, double cRoot) {

    // 0. Base case, only one symbol in [l, r]
    if (l == r) {
        Symbol sym = symbols.get(l);
        codeTable.put(sym.character, U);
        return;
    }
    if (l > r)
        return;

    // 1. Create initial bins  $Im^*$ 
    int k = sortedDiameters.size();
    // List of List with original indexes
    List<List<Integer>> initialBins = new ArrayList<>(k);
    for (int i = 0; i < k; i++) {
        initialBins.add(new ArrayList<>());
    }

    double P_start = symbols.get(l).cumulativeProbStart; //  $P_{l-1}$ 
    double P_end = symbols.get(r).cumulativeProbEnd; //  $P_r$ 
    // Total weight of this recursion step ( $w(v)$ )
    double w = P_end - P_start;

    // No more weight to distribute
    if (w <= TOLERANCE)
        return;

    // L in paper
}

```

```

double currentL = P_start;

// Calculate edges Lm*, Rm* (relative limits inside of w) and assign symbols
// Index m is Bin m+1 in Paper (0 to k-1 here)
for (int m = 0; m < k; m++) {
    Perle diamInfo = sortedDiameters.get(m);
    double binWidth = w * Math.pow(2.0, -cRoot * diamInfo.cost);
    double currentR = currentL + binWidth;

    // Find symbols with middle point in [currentL, currentR)
    for (int i = 1; i <= r; i++) {
        Symbol sym = symbols.get(i);
        // Centerpoint s_i = P_{i-1} + p_i / 2
        // Wahrscheinlichkeitsmittelpunkt, Heuristik
        double midPoint = sym.cumulativeProbStart + sym.probability / 2.0;

        // Check if fits to Bin m
        if (midPoint >= currentL - TOLERANCE && midPoint < currentR - TOLERANCE) {
            // Add original index to Bin m
            initialBins.get(m).add(i);
        }
    }
    // Update for next Bin
    currentL = currentR;
}

// 2. Very simplified version of left shift from paper
// Just creates the final bin lists and skips empty bins
List<List<Integer>> finalBins = new ArrayList<>();
// Follow index of next available symbol
int firstItemIndex = 1;
for (int m = 0; m < k; m++) {
    List<Integer> currentBinContent = initialBins.get(m);
    if (currentBinContent.isEmpty()) {
        // Bin is empty: Geht next available symbol
        if (firstItemIndex <= r) {
            // (In paper: find bin where the symbol was originally -> very complex,
            // not manage to implement that correctly :(, so here just add next
            // element to bin to fill it)
            finalBins.add(Collections.singletonList(firstItemIndex));
            firstItemIndex++;
        } else {
            // No more elements to fill bin -> bin stays empty (ignored, very sad I
            // know)
        }
    } else {
        List<Integer> effectiveBinContent = new ArrayList<>();
        for (int originalIndex : currentBinContent) {
            // Just add if not already used by shifting
            if (originalIndex >= firstItemIndex) {
                effectiveBinContent.add(originalIndex);
            }
        }
        // If bin empty because of skipping, but there are still elements, then just
        // use next
        if (effectiveBinContent.isEmpty() && firstItemIndex <= r) {
            finalBins.add(Collections.singletonList(firstItemIndex));
            firstItemIndex++;
        } else if (!effectiveBinContent.isEmpty()) {
            finalBins.add(effectiveBinContent);
            // Set index for next element after last of this bin
            firstItemIndex = effectiveBinContent.get(effectiveBinContent.size() - 1)
+ 1;
        }
        // Otherwise bin stays empty
    }
}

// Check if all elements were assigned
if (firstItemIndex <= r) {
    // Elements are still there, that are not inside a bin -> problem somewhere

```

```

104         // Add to last non empty bin
        System.out.println(
            "Irgendwas broken, eyyy ich kann nicht mehr Elemente[" +
            firstItemIndex + "... " + r + "] nicht zugeordnet");
106         if (!finalBins.isEmpty()) {
            List<Integer> lastBin = finalBins.get(finalBins.size() - 1);
108             for (int i = firstItemIndex; i <= r; i++) {
                lastBin.add(i);
110             }
        } else {
112             System.out.println("FATAL");
            // Fill first bin, emergency lol
            List<Integer> onlyBin = new ArrayList<>();
114             for (int i = 1; i <= r; i++)
                onlyBin.add(i);
116             finalBins.add(onlyBin);
118         }
    }

120
    // 3. Right shift
    // in paper: if all in bin 1 then move last element to bin 2
    // Here checking this
122
124     if (finalBins.size() == 1 && finalBins.get(0).size() == (r - 1 + 1) && k > 1) {
        List<Integer> firstBin = finalBins.get(0);
126         // Only makes sense if more than 1 element in bin
        if (firstBin.size() > 1) {
128             // Remove last index
            int lastElementIndex = firstBin.remove(firstBin.size() - 1);
130             List<Integer> secondBin = new ArrayList<>();
            secondBin.add(lastElementIndex);
132             // Only add if space
            if (finalBins.size() < k) {
134                 finalBins.add(secondBin);
            } else {
136                 System.out.println("No space in second bin");
                firstBin.add(lastElementIndex); // Revert
138             }
        }
    }

140
    // 4. Recursion for every non empty final bin
    for (int m = 0; m < finalBins.size(); m++) {
142         List<Integer> currentBinIndices = finalBins.get(m);
        if (!currentBinIndices.isEmpty()) {
144             // First index in bin
            int bin_l = currentBinIndices.get(0);
146             // Last index
            int bin_r = currentBinIndices.get(currentBinIndices.size() - 1);
148             // Find color / index for this bin
            // in paper quite complex so here the m-th non empty bin gets the m-th
            // cheapest
150             // color
            int colorIndex = sortedDiameters.get(m).digit;
152
            // Recursive call
            generateCodesGolinLi(symbols, bin_l, bin_r, U + colorIndex, codeTable,
154                 sortedDiameters, cRoot);
        }
    }
156
158 }

```

2.4 Strategie 3: Dynamische Programmierung Golin/Rote

2.4.1 Kernidee

Der in Strategie 2 umgesetzte Algorithmus bringt zufriedenstellende Lösungen für dieses Teilproblem in einer sehr skalierbaren Laufzeit. Dennoch sind die Beispiellängen der BwInf-Webseite besser als die berechneten Werte dieses Programms. Daher wird vermutet, dass die Werte die Gesamtlänge einer optimal kodierten Nachricht sind. Um diese Vermutung zu überprüfen, wird im Folgenden ein anspruchsvoller

dynamischer Programmieransatz implementiert, der von Golin und Rote in [3] vorgestellt wird. Der Algorithmus garantiert eine optimale Kodierung von k Quellsymbolen in einer Laufzeit von $\mathcal{O}(k^{C+2})$, wenn die Kosten C der Kodierungsbuchstaben eine ganze positive Zahl ist. Dieser Ansatz wurde zuletzt gewählt, da die Eingabebeispiele große Werte von k haben (insbesondere *schmuck8.txt* und *schmuck9.txt*, wegen den vielen verschiedenen (chinesischen/japanischen) Zeichen) und C bis zu 6 wird, was die Laufzeit stark beeinflusst, aber noch im Rahmen des Möglichen bleibt. Der Ansatz, das Problem in ein ILP umzuformen wurde versucht, aber aufgrund exponentieller Laufzeiten verworfen.

Aus Kapitel 1 und 2.1 ist klar geworden, dass der einfache greedy Ansatz von Huffman für ungleiche Buchstabenkosten nicht mehr garantiert zum optimalen Codebaum führt, aus dem die Codes erstellt werden können. Das Ziel des Folgenden beschriebenen Ansatzes ist daher (zumindest vom Konzept her) die Konstruktion eines solchen optimalen Codebaums.

Die Kernidee dieses Algorithmus ist es, das Problem der optimalen Codebaum-Konstruktion in ein Kürzeste-Wege-Problem auf einen **Zustandsgraphen** zu überführen. Anstatt wie Huffman den Baum von den Blättern zur Wurzel (Bottom-Up) aufzubauen, verfolgt dieser Ansatz eine Top-Down-Strategie mit dynamischer Programmierung (DP). DP ist eine Methode, bei dem ein Problem in Teilprobleme zerlegt wird, deren Lösungen gespeichert werden, um sie zur Berechnung der Gesamtlösung wiederzuverwenden.

Der Algorithmus erstellt gedanklich einen gewichteten, gerichteten, azyklischen Graphen. Jeder **Knoten** in diesem Graphen steht für einen eindeutigen **Zustand** während des schrittweisen Aufbaus des Codebaums. (Wichtig: Graph und Baum sind separat zu betrachten. Der Graph stellt Möglichkeiten dar, **wie** man den Codebaum aufbauen kann). Dieser Zustand wird als "**Signatur**" $S = (m; l_1, l_2, \dots, l_C)$ bezeichnet. Diese Signatur fasst alle wichtigen Informationen über den aktuellen Baufortschritt des Baums zusammen (wenn es im Folgenden um den Zustandsgraphen geht, werden Signatur und Knoten und Zustand als Synonyme verwendet):

- m : Gibt an, wie viele der k Quellsymbole bereits einen finalen Platz im entstehenden Baum erhalten haben (d.h., ihr Pfad endet an einem Blatt).
- $(m; l_1, l_2, \dots, l_C)$: Beschreiben die Anzahl der aktuell "offenen" Astenden (potenzielle Blätter) auf den nächsten C relevanten Tiefen-Ebenen des Baumes. Diese bilden die "Front", an der der Baum weiter ausgebaut werden kann.

Eine gerichtete Kante von einer Signatur S zu einer Signatur S' im Graphen steht für einen **Expansions-schritt** beim Aufbau des Baums. Dieser Schritt entscheidet, was mit der aktuellen "Wachstumsfront" des Baumes, wo sich l_1 offene Endknoten befinden, geschieht. Er entscheidet, wie diese offene Endknoten behandelt werden. Dies wird durch eine Variable q quantifiziert, was die Anzahl dieser l_1 offenen Endknoten, die in diesem Schritt ausgewählt werden, um weiter zu expandieren, ist. Das bedeutet, diese q Knoten werden zu inneren Knoten des Baumes und erhalten neue Kinder entsprechend den Buchstaben des Zielalphabets und deren Kosten. Die verbleibenden $(l_1 - q)$ Knoten dieser Gruppe werden in diesem Schritt zu finalen Blättern, wo die Pfade dann enden.

Das Gewicht der Kanten zwischen den Signaturen in dem Graph, gibt die zusätzlichen Kosten an, die durch diesen Expansionsschritt entstehen. Da sich durch den Expansionsschritt die Pfadlänge zu diesen noch offenen Enden erhöht, steigt ihr Beitrag zu den Gesamtkosten. Die Kantenkosten sind daher die Summe der Wahrscheinlichkeiten dieser "wartenden" Symbole.

Ein wichtiger Aspekt (für die Effizienz, damit $\mathcal{O}(k^{C+2})$ erreicht wird, und nicht $\mathcal{O}(k(n-1)^{C+2})$) des Algorithmus, ist die **Reduktion der Signaturen**. Wenn ein Expansionsschritt zu einer Signatur führt, die mehr als die benötigten k Blätter hätte, werden die überzähligen, tiefsten Blätter entfernt ("reduce"-Operation). Dadurch wird sichergestellt, dass nur die Signaturen betrachtet werden, die maximal k Blätter kodieren, was die Größe des Zustandsgraphen eingrenzt.

Ein Pfad von der Signatur S_0 (repräsentiert die leere Wurzel der Baums) zum Zielzustand (alle k Symbole sind im Baum platziert, keine offenen Enden mehr) entspricht der gesamten Sequenz für den Bau von einem präfixfreien Codebaum. Der kürzeste Pfad in diesem Zustandsgraphen entspricht der Sequenz des Baus des Codebaums mit den minimal möglichen durchschnittlichen Gesamtkosten. Die Länge (Summe der Kantengewichte) dieses kürzesten Pfades ist dieser optimale Kostenwert.

Da der Graph keine Zyklen enthält, kann der kürzeste Pfad effizient mit DP gefunden werden (hat Ähnlichkeiten zu Dijkstra mit der PriorityQueue). Der Algorithmus durchläuft die Zustände (Signaturen)

so, dass sichergestellt wird, dass ein Zustand erst verarbeitet wird, wenn die optimalen Kosten zu diesem Zustand bekannt sind (topologische Reihenfolge). Für jeden erreichten Zustand S werden alle möglichen nächsten Zustände S' (durch Expansion mit q) betrachtet. Die Kosten, um S' über S zu erreichen, werden mit den bisher besten bekannten Kosten für S' verglichen und gegebenenfalls aktualisiert. Dabei wird gespeichert, von welchem Vorgänger S und mit welcher Entscheidung q der beste Weg nach S' führte. Das bedeutet, zu jedem Zustand S' wird gespeichert, wie man zu S' gelangt ist.

Es ist anzumerken, dass der Zustandsgraph nicht explizit komplett aufgebaut und dann durchsucht wird. Dies wäre wegen der potenziell riesigen Anzahl möglicher Signaturen für größere Eingaben sehr ineffizient. Stattdessen wird der relevante Teil des Graphen implizit und schrittweise während der Ausführung des DP aufgebaut und gleichzeitig ausgewertet. Mit diesem Prozess wird der kürzeste Pfad gefunden und gespeichert, sowie seine Länge. Der gerade beschriebene Algorithmus zum Erstellen des Zustandsgraphen und das Finden des kürzesten Pfads wird in [3] vorgestellt. Das Finden der Codetabelle wird allerdings nicht mehr explizit ausgeführt und im Folgenden wird dieser Prozess beschrieben:

Sobald die minimalen Kosten zum Gelingen zu dem Zielzustand berechnet sind, wird der optimale Weg rekonstruiert. Durch **Backtracking** (Zurückverfolgen der gespeicherten optimalen Vorgänger vom Ziel zum Startknoten) erhält man den kürzesten Pfad. Dieser Pfad repräsentiert die **Sequenz der optimalen Expansionsentscheidungen (q -Werte)**, die zur Konstruktion des optimalen Codebaums führen.

Diese Sequenz dient als Bauplan für diesen Baum. Anstatt nun einen expliziten Baum im Speicher aufzubauen, kann der optimale Codebaum simuliert werden, indem dieser Bauplan Schritt für Schritt abgearbeitet wird. Dabei werden die aktiven Codewort-Präfixe und ihre Tiefen verwaltet und die Codewörter werden direkt generiert.

Obwohl sich die Konstruktion der optimalen Baumstruktur wegen der ungleichen Buchstabenkosten stark vom Standard-Huffman unterscheidet, bleibt das Prinzip der Zuweisung von Symbolen zu Blättern dasselbe: Das Quellsymbol mit der höchsten Wahrscheinlichkeit wird dem Blatt mit der geringsten Tiefe im resultierenden optimalen Baum zugeordnet, das zweitwahrscheinlichste dem Blatt mit der zweitgeringsten Tiefe usw. Die finalen Codewörter ergeben sich dann wie üblich aus den Pfaden von der Wurzel zu diesen zugewiesenen Blättern. In 2.4.2 (Umsetzung) wird genauer auf die verwendete Methode des Erstellens der Codetabelle eingegangen

Zusammengefasst funktioniert der Algorithmus aus [3], da mit der dynamischen Programmierung gezielt alle sinnvollen Möglichkeiten durchgegangen werden, wie man den Codebaum aufbauen kann. Die Signatur speichert dabei alle wichtigen Infos, die später gebraucht werden, um die bestmöglichen Entscheidungen des Baumaufbaus zu treffen. Da die Kosten im Zustandsgraph genau den tatsächlichen Aufbaukosten des Codebaums entsprechen, garantiert der kürzeste Weg im Graph, dass die günstigste Bauweise des Codes gefunden wird.

2.4.2 Umsetzung

Die Implementierung des DP für den Graphen basiert auf der in [3, Figure 6] dargestellten Struktur des Algorithmus. Im Folgenden wird der gesamte Prozess zur Lösung der Teilaufgabe B gezeigt, wobei der Fokus auf den Schritten liegt, die zur Berechnung der optimalen Kosten führen und aufzeigen, wie daraus die finale Codetabelle erstellt wird.

Wrapperklassen, die die Ergebnisse von einzelnen Schritten speichern, um sie zu den nächsten Schritten zu Verfügung zu stellen, werden nicht extra explizit angesprochen. Eine wichtige häufig verwendete Klasse ist allerdings die **Signature** Klasse, die eine Signatur im Graphen darstellt und die in 2.4.1 entsprechend beschriebene Attribute speichert.

Der Code ist wie folgt strukturiert:

1. Vorverarbeitung und Initialisierung

a) Einlesen der Daten und Frequenzanalyse

Diese zwei Teilschritte sind identisch zu der implementierten Version in den vorherigen Strategien. Allerdings werden zusätzlich die eingelesenen Zeichen bei der Frequenzanalyse bereits hier nach ihrer Häufigkeit sortiert, da dies für kommende Schritte nötig ist.

b) Berechnung der kumulativen Frequenzen

Um die Kosten für die Kanten bei der Erstellung des Zustandsgraphen im Graphen effizient zu berechnen, wird ein Array erstellt. Das i -te Element ist dabei die Summe der Häufigkeiten

der Symbole von Index i bis $k - 1$. Dies erlaubt die Berechnung der Kantenkosten (Summe der Wahrscheinlichkeiten der noch nicht platzierten Symbole) in $\mathcal{O}(1)$.

c) **Berechnung des charakteristischen Vektors**

Aus der Liste der Kodierungsbuchstabenkosten wird der charakteristische Vektor d berechnet. Dieser Vektor $d = (d_1, \dots, d_C)$ ist eine Zusammenfassung der Kostenstruktur des Zielalphabets, denn er gibt an, wie viele Kodierungsbuchstaben (d_j) genau die Kosten j haben. Er wird im Algorithmus gebraucht, um bei einem Expansionsschritt (also wenn q Knoten erweitert werden) zu berechnen, wie viele neue "offene Enden" (potenzielle Blätter) auf welchen relativen Tiefen ($+1, +2, \dots, +C$) entstehen und wie sich dadurch die Signatur für den nächsten Zustand verändert [3, vgl. Lemma 3].

2. DP zur Kostenminimierung

a) **Erstellung der Variablen für die DP**

Für den kommenden Teil mit der Dynamischen Programmierung müssen wichtige Datenstrukturen erstellt werden, um die Ergebnisse der DP zu speichern:

- `HashMap opt`: speichert für jede bisher erreichte Signatur, was die bisher gefundenen minimalen Kosten sind ($OPT[S]$ im Paper).
- `HashMap pred`: speichert, von welcher Vorgänger-Signatur und mit welcher Expansionsentscheidung q sie optimal erreicht wurde. Dies ist essenziell für das spätere Backtracking.
- Es werden (wie bei Dijkstra) ein Start S_0 und Zielknoten `finalState` für den Graphen definiert (S_0 : Startsignatur, `finalState`: Zielsignatur mit $(k; 0, \dots, 0)$), damit klar ist, wann mit der Suche nach dem kürzesten Pfad aufgehört werden kann.
- Eine `PriorityQueue pq` wird erstellt und S_0 wird hinzugefügt. Sie steuert die Exploration des Zustandsgraphen in einer ähnlichen Weise wie Dijkstra, indem Zustände mit den aktuell geringsten Kosten zuerst verarbeitet werden, was die topologische Reihenfolge sicherstellt.

b) **Hauptschleife für DP**

In diesem Abschnitt wird der im Paper beschriebene DP-Algorithmus zur impliziten Konstruktion und Exploration des Zustandsgraphen implementiert:

Die Hauptschleife wird definiert: Solange es Zustände in der `pq` gibt, wird der Zustand *current* mit den geringsten Kosten *currentCost* entnommen. Es wird überprüft, ob dieser Zustand bereits über einen kürzeren Pfad erreicht wurde oder ob das Ziel bereits mit geringeren Kosten gefunden wurde. Außerdem wird überprüft, ob der Zielknoten *finalState* erreicht wurde. Innerhalb dieser Schleife wird auch der in 2.4.1 beschriebene Expansionsschritt durchgeführt, wo für die aktuelle Signatur alle möglichen nächsten Zustände generiert werden:

- i. Die Anzahl der offenen Enden an der Front (l_1) wird aus der Signatur geholt
- ii. Die Kosten für den Expansionsschritt werden mit dem Array aus Schritt 1b berechnet
- iii. Eine Schleife iteriert über alle möglichen Expansionsentscheidungen q (von 0 bis l_1)
- iv. Für jedes q wird die nächste Signatur (vor der Reduktion der Signaturen) berechnet
- v. Anschließend wird der in 2.4.1 beschriebene Prozess von der Reduktion der Signaturen angewendet
- vi. Wenn nun der Pfad zu dieser neuen Signatur besser ist, werden *pred* und *opt* aktualisiert

3. Ergebnissicherung von DP

Nach der DP-Schleife wird überprüft, ob tatsächlich ein Endzustand erreicht wurde und die finalen minimalen Kosten (Länge des kürzesten Pfads im Graph) abgespeichert.

4. Rekonstruktion der Blattiefen

Nun wird der erste Teil der Erstellung der Codetabelle durchgeführt. Ein intuitiver Ansatz wäre, mittels Backtracking den optimalen Pfad zurückzuverfolgen und daraus den optimalen Codebaum zu erstellen. Allerdings bin ich bei der Recherche für diese Aufgabe auf den canonical Huffman Code gestoßen, der die Codes generiert, ohne dabei den Baum explizit zu bauen.¹ Daher wird

¹Das fand ich interessant und die kleine (also... in meiner Vorstellung kleine) Änderung wollte ich implementieren. Spoiler: Die geplante Stunde wurde zu 20, meine To-do-Liste hat gelacht, und mein Schlafrythmus wurde (mal wieder) dabei rekursiv aufgelöst – leider ohne Memoization. Ich habe leider viel zu spät mit der Bearbeitung dieser Aufgabe angefangen, aber naja passiert...

im Folgenden der erste Teil der Erstellung der Codetabelle, basierend auf den canonical Huffman Code, ohne die explizite Erstellung des Codebaums, implementiert. Dies wird gemacht, indem der optimale Pfad genommen wird, um zu ermitteln, wie viele der k Blätter im optimalen Baum auf welcher spezifischen Tiefe landen müssen. Mit dem aus Schritt 2 berechneten Pfad wird der optimale Bauprozess des Codebaums "nachgespielt", wobei nur gesichert wird, wann die Blätter finalisiert werden und auf welcher Tiefe. Denn um die finale Codetabelle zu erstellen, wird nicht die volle Baumstruktur benötigt, sondern nur die **Verteilung der Blatttiefen**.

- a) Zunächst wird mit der *pred* Map der Pfad von der Zielsignatur zurück zur Startsignatur S_0 verfolgt. Die dabei gesammelten Informationen zur Erstellung des Baums, wie die q Werte, werden in einer Liste *path* gespeichert und anschließend umgedreht, um die optimale Sequenz von S_0 zum Ziel zu erhalten.
- b) Eine HashMap *leavesFinishedAtDepth* wird angelegt, in der das Endresultat gespeichert wird. Diese soll die exakte Anzahl der Blätter halten, die im optimalen Codebaum auf jeder Tiefe enden müssen. Zusätzlich werden direkt die Blätter, die nach dem Start bei S_0 existieren, unter der Berücksichtigung der initialen Reduktion, ermittelt.
Um die Vorwärtssimulation der Erstellung des Baums zu implementieren, wird durch die optimale q -Sequenz (*path*) iteriert. Innerhalb dieser Schleife wird bestimmt, wie viele der Blätter an der aktuellen Front expandiert und wie viele finalisiert werden. Anschließend wird die Reduktionslogik simuliert, indem berechnet wird, wie viele Blätter insgesamt existieren würden und wie viele davon entfernt werden müssen, um k nicht zu überschreiten. Dann wird die Anzahl der Blätter, die bei der aktuellen Simulationstiefe *simDepth* tatsächlich finalisiert werden, berechnet und in die *leavesFinishedAtDepth* Map hinzugefügt. Schließlich wird überprüft, ob die berechneten Werte tatsächlich stimmen und *leavesFinishedAtDepth* wird zurückgegeben.

5. Generierung der Codetabelle

Um nun die Codetabelle zu erstellen, werden die aus Schritt 1a. (Frequenzanalyse) und Schritt 4. (Blatttiefen) berechneten Werte verwendet. Diese Methode funktioniert, indem man diese Anforderungen (die berechneten Werte) bekommt und daraus eine konkrete, präfixfreie Codetabelle erstellt, die diese Anforderungen erfüllt. Dabei ist sie unabhängig vom Golin-Rote-Algorithmus und betrachtet nur das Teilproblem: "Finde eine Menge von k präfixfreien Codes, sodass diese Codes die vorgegebene Tiefe besitzen, und ordne diese den Symbolen P_1 bis P_k in der gegebenen Reihenfolge zu." Dies ist ein Standardproblem. Wenn man die Längen (oder hier äquivalent: die Kosten/Tiefen) der Codewörter eines optimalen Codes kennt, gibt es Algorithmen, um einen tatsächlichen präfixfreien Code mit genau diesen Längen zu konstruieren. Das bekannteste Beispiel dafür ist die Konstruktion von **Canonical Huffman Codes**. Das Folgende implementiert eine Variante davon, der einen systematischen, greedy Generierungs- und Zuweisungsansatz verfolgt:

Zunächst wird eine Liste von k Targets (TargetInfo Objekte, bzw. auch Ziele genannt) erstellt. In dieser Liste wird für jedes der k Symbole, seine zugehörige optimale Tiefe (analog zu seinen Kosten) gespeichert. Diese Liste wird anschließend nach Tiefe sortiert, damit Codewörter für geringere Tiefen bevorzugt zugewiesen werden. Außerdem wird eine Kandidatenliste *candidatePool* erzeugt, die generierte, aber noch nicht verwendete, Codewort-Kandidaten speichert.

Dann erzeugt ein Generator (eine Deque) systematisch die Codewort-Kandidaten ("0", "1", ..., "00", "01", ...). Es wird über die Targets, die jeweils ein Symbol s und seine benötigte Tiefe d speichert, iteriert, beginnend mit dem mit den geringsten Kosten. Zuerst wird im *candidatePool* nach einem passenden Kandidaten für s gesucht. Wenn dieser präfixfrei zu bereits vergebenen Codes ist, wird dieser verwendet. Falls kein passender Code im Pool war, werden neue Kandidaten aus dem Generator genommen. Dabei wird jeder Kandidat auf Kosten und Präfixfreiheit überprüft:

- Kosten übereinstimmend und präfixfrei: Code wird zugewiesen
- Kosten übereinstimmend, aber nicht präfixfrei: Kandidat wird (zurück) in den Pool gelegt
- Kosten nicht übereinstimmend: Kandidat wird in den Pool gelegt

Dieser Generierungs- und Prüfprozess wird fortgesetzt, bis ein passender, präfixfreier Code für das aktuelle Target gefunden wird oder ein Generierungslimit erreicht ist.

Nachdem alle k Ziele abgearbeitet wurde, wurde die vollständige, präfixfreie Codetabelle gefunden.

6. Ausgabe der Codetabelle

Analog zu den bisherigen Strategien.

2.4.3 Komplexitätsanalyse

Für das Verständnis ist es empfehlenswert, den Code nebenbei offen zu haben, um die Laufzeiten nachzuvollziehen. Für die Komplexitätsanalyse werden zur besseren Übersicht die verwendeten Variablen im Folgenden nochmals erläutert:

- L : Gesamtlänge des Eingabetextes
- k : Anzahl der einzigartigen Quellsymbole (im Paper oft als n bezeichnet)
- n : Größe des Zielalphabets (Anzahl der verschiedenen Kostenwerte)
- C : Maximale Kosten eines Zeichens des Zielalphabets
- V : Anzahl der Knoten (Signaturen) im impliziten Zustandsgraphen
- E : Anzahl der Kanten im impliziten Zustandsgraphen

Schritt	Laufzeit	Speicherbedarf
Vorverarbeitung	$\mathcal{O}(L + k \log k)$	$\mathcal{O}(k)$
DP zur Kostenminimierung	$\mathcal{O}(k^{C+2} \cdot C)$	$\mathcal{O}(C \cdot k^{C+1})$
Ergebnissicherung von DP	$\mathcal{O}(k^{C+1} \cdot C)$	$\mathcal{O}(1)$
Rekonstruktion der Blatttiefen	$\mathcal{O}(L_{path} \cdot k \log k)$	$\mathcal{O}(L_{path} \cdot C)$
Generierung der Codetabelle	$\mathcal{O}(k \cdot L_{max})$	$\mathcal{O}(k \cdot L_{max})$
Ausgabe Codetabelle	$\mathcal{O}(k \log k)$	$\mathcal{O}(k)$
Gesamt	$\mathcal{O}(C \cdot k^{C+2})$	$\mathcal{O}(C \cdot k^{C+1})$

Table 4: Laufzeit- und Speicherkomplexität Teilaufgabe B mit Strategie 3

- **Vorverarbeitung:**
 - **Laufzeit:** Häufigkeitsanalyse iteriert durch den Text $\mathcal{O}(L)$. Sortieren der k Symbole liegt in $\mathcal{O}(k \log k)$; Gesamt: $\mathcal{O}(L + k \log k)$
 - **Speicher:** *frequencyMap*, *sortedSymbols*, *freqCounts*, *cumFreq* sind jeweils in $\mathcal{O}(k)$, der charakteristische Vektor ist ein Array der Größe C , also in $\mathcal{O}(C)$; Gesamt: Dominiert von $\mathcal{O}(k)$.
- **DP zur Kostenminimierung:**
 - **Laufzeit:** Schritt 2a in $\mathcal{O}(C)$. Die Hauptschleife von Schritt 2b läuft im schlimmsten Fall so oft, wie Kanten im Graphen (ähnlich wie Dijkstra), was $\mathcal{O}(E)$ ist. Die kleinste Signatur aus der PriorityQueue zu holen, ist in $\mathcal{O}(\log |PQ|)$, wo $|PQ|$ die Größe der Queue ist. Da sie im schlimmsten Fall V groß wird: $\mathcal{O}(\log V) = \mathcal{O}(\log(k^{C+1})) = \mathcal{O}(C \log k)$.
Das Überprüfen, ob der Zielknoten erreicht wurde, ist in $\mathcal{O}(C)$, da m und die Liste der Länge C verglichen werden müssen. Die Kostenberechnung der Kanten ist konstant wegen *cumFreq* und die Schleife für die Expansionsentscheidungen läuft bis zu $\mathcal{O}(k)$ mal, da sie $l_1 + 1$ mal läuft und $l_1 \leq k$. In dieser Schleife ist alles in $\mathcal{O}(C)$ bis auf das Hinzufügen in die PriorityQueue das in $\mathcal{O}(\log |PQ|) = \mathcal{O}(C \log k)$, um das eingefügte Element an die richtige Position zu bringen, da sie als Min-Heap implementiert ist.
Die Kosten pro Iteration der q Schleife (Expansionsentscheidungen) liegen somit bei $\mathcal{O}(C + C \log k) = \mathcal{O}(C \log k)$.
Die Hauptschleife von 2b hat somit Kosten von $\mathcal{O}(C \log k) \cdot \mathcal{O}(k \cdot C \log k)$ pro Iteration.
Gesamtkosten: Normalerweise wäre mit der PriorityQueue die Laufzeit bei ca. $\mathcal{O}(E \log V) = \mathcal{O}(C \cdot k^{C+2} \cdot \log k)$ (siehe Dijkstra). Aber [3, Richtung Ende Kapitel 4] argumentiert, dass die Laufzeit in $\mathcal{O}(C \cdot k^{C+2})$ ist, wegen der Struktur des Problems und auch wegen der (impliziten) topologischen Bearbeitungsreihenfolge. C wird allerdings oft weggelassen, da diese in der Realität oft nur eine sehr kleine Konstante ist.

- **Speicher:** Der Speicher wird hier dominiert von den HashMaps *opt*, *pred* und der PriorityQueue *pq*. Die Maps sind in $\mathcal{O}(k^{C+1})$, da die erreichten Zustände als Schlüssel gespeichert werden. Die Anzahl der Zustände V' ist $\mathcal{O}(k^{C+1})$, wo V' die Anzahl der Knoten im reduzierten Graphen ist und jede Signatur speichert eine Liste der Länge C . Die PriorityQueue kann im schlimmsten Fall einen sehr großen Teil der Zustände haben, bevor sie verarbeitet werden. Sie ist in der selben Komplexität wie die Maps, da sie bis zu $\mathcal{O}(V')$ groß werden kann.
- **Ergebnissicherung von DP:**
 - **Laufzeit:** Um zu überprüfen, ob ein Zielknoten erreicht wurde (gilt auch für andere Objekte, mit derselben Signatur), muss im schlimmsten Fall über V Elemente iteriert werden, die jeweils $\mathcal{O}(C)$ brauchen, um überprüft zu werden. Gesamt daher in $\mathcal{O}(k^{C+1} \cdot C)$.
 - **Speicher:** Konstant
- **Rekonstruktion der Blatttiefen:**
 - **Laufzeit:** Für das Backtracking wird $\mathcal{O}(L_{path})$ gebraucht, mit L_{path} als Länge des optimalen Pfads. Für die Simulation für das Erstellen des Baums, läuft die Schleife L_{path} mal. Innerhalb dieser Schleife dominiert das Sortieren von *activeLeaves.Keyset()* mit einer Laufzeit von $\mathcal{O}(k \log k)$. Gesamt: Im worst Case also ca. $\mathcal{O}(L_{path} \cdot k \log k)$.
 - **Speicher:** Hier dominiert die Liste *path* mit $\mathcal{O}(L_{path} \cdot C)$.
- **Generierung der Codetabelle:**
 - **Laufzeit:** Um zunächst die Targets (Ziele) zu erstellen, iteriert die Schleife über *depthsCounts* und k Symbole. Geschätzt benötigt das $\mathcal{O}(k + k \log k)$, da die Tiefen danach noch sortiert werden. Die Hauptschleife iteriert über k Targets und die Pool Prüfung iteriert über maximal k zugewiesene Codes. Dort braucht der Präfix Check, wenn L_{max} die maximale Codewortlänge ist, $\mathcal{O}(L_{max})$. Also braucht jeder Kandidat $\mathcal{O}(k \cdot L_{max})$. **Insgesamt hängt die Laufzeit stark davon ab, wie schnell passende, präfixfreie Codes gefunden werden.** Im best Case - wenn sie schnell gefunden werden - beträgt die Laufzeit $\mathcal{O}(k \cdot L_{max})$. Der worst Case kann sehr groß sein, was aber nicht direkt einfach von k oder C abhängt.
 - **Speicher:** Der Speicher für *codeMap*, *assignedCodesList* ist bei $\mathcal{O}(k \cdot L_{max})$. Da der Generator theoretisch sehr groß werden kann, ist der Speicher für diese Methode schwer abzuschätzen, sollte aber in der Praxis noch akzeptabel sein.

2.4.4 Beispiele

Hier die Ausgaben des Programmes zu den Beispielen auf der BwInf-Webseite. Die gesamte Ausgabe ist in **Aufgabe1/Ausgaben/AusgabenBStrategie3.txt** zu finden. Zusätzlich ist hier die Ausführungszeit angegeben (intel i3-12100f, mit 32GB Ram).

1. schmuck1.txt

```

1. Preprocessing
  k = 25, C = 2, n=3, S0 = (0; 2, 1)
2a. Running Dynamic Programming (Dijkstra-like)
  Reached target finalState = (25; 0, 0) with cost 191
2b. DP Finished. Processed 319 states
  Total states in OPT table: 262
3. Minimum Total Cost (Sum Freq*Depth): 191
4. Reconstructing Code
  Reconstructing path
-----
Execution time: 55 ms
-----
{
  'e': 2 (Freq: 9, Länge: 2)
  't': 02 (Freq: 6, Länge: 3)
  '␣': 12 (Freq: 5, Länge: 3)
  'i': 000 (Freq: 3, Länge: 3)

```

'n': 001 (Freq: 3, Länge: 3)
'r': 010 (Freq: 3, Länge: 3)
'w': 011 (Freq: 3, Länge: 3)
'B': 012 (Freq: 2, Länge: 4)
'I': 102 (Freq: 2, Länge: 4)
'": 002 (Freq: 2, Länge: 4)
'b': 112 (Freq: 2, Länge: 4)
'f': 1000 (Freq: 2, Länge: 4)
's': 1001 (Freq: 2, Länge: 4)
'D': 1010 (Freq: 1, Länge: 4)
'F': 1011 (Freq: 1, Länge: 4)
'N': 1100 (Freq: 1, Länge: 4)
'W': 1101 (Freq: 1, Länge: 4)
'a': 1002 (Freq: 1, Länge: 5)
'd': 1012 (Freq: 1, Länge: 5)
'h': 1102 (Freq: 1, Länge: 5)
'k': 1112 (Freq: 1, Länge: 5)
'm': 11100 (Freq: 1, Länge: 5)
'o': 11101 (Freq: 1, Länge: 5)
'u': 11110 (Freq: 1, Länge: 5)
'ü': 11111 (Freq: 1, Länge: 5)

Gesamtlänge der Botschaft 191 (in mm) bzw. 19.1cm

Kodierte Nachricht: 0121101102110010111210010221102021210001111101012002101000021
201211110001101221001011200002200112102001100011101010111001002020001112011202021
12201120101122002

2. schmuck2.txt

1. Preprocessing

$$k = 9, C = 5, n=2, S0 = (0; 1, 0, 0, 0, 1)$$

2a. Running Dynamic Programming (Dijkstra-like)

Reached target finalState = (9; 0, 0, 0, 0, 0) with cost 135

2b. DP Finished. Processed 246 states

Total states in OPT table: 268

3. Minimum Total Cost (Sum Freq*Depth): 135

4. Reconstructing Code

Reconstructing path

Execution time: 59 ms

```
{
  'a': 0 (Freq: 33, Länge: 1)
  '␣': 101 (Freq: 1, Länge: 11)
  'b': 110 (Freq: 1, Länge: 11)
  'g': 111 (Freq: 1, Länge: 15)
  'd': 1001 (Freq: 1, Länge: 12)
  'e': 10001 (Freq: 1, Länge: 13)
  'f': 100001 (Freq: 1, Länge: 14)
  'c': 1000000 (Freq: 1, Länge: 11)
  'h': 1000001 (Freq: 1, Länge: 15)
}
```

Gesamtlänge der Botschaft 135 (in mm) bzw. 13.5cm

[illegible]


```

'm': 1001 (Freq: 1, Länge: 12)
'f': 00001 (Freq: 1, Länge: 9)
'h': 000001 (Freq: 1, Länge: 10)
'k': 0000001 (Freq: 1, Länge: 11)
'e': 00000000 (Freq: 1, Länge: 8)
'n': 00000001 (Freq: 1, Länge: 12)
}

```

Gesamtlänge der Botschaft 137 (in mm) bzw. 13.7cm

Kodierte Nachricht: 00100010100100000000000000001110000010111010000001010110010000
0001

5. schmuck5.txt

```

1. Preprocessing
   k = 41, C = 6, n=7, S0 = (0; 2, 1, 1, 1, 1, 1)
2a. Running Dynamic Programming (Dijkstra-like)
   Reached target finalState = (41; 0, 0, 0, 0, 0, 0, 0) with cost 3162
2b. DP Finished. Processed 485 states
   Total states in OPT table: 1068
3. Minimum Total Cost (Sum Freq*Depth): 3162
4. Reconstructing Code
   Reconstructing path
-----
Execution time: 105 ms
-----
{
  '␣': 2 (Freq: 151, Länge: 2)
  'e': 00 (Freq: 110, Länge: 2)
  't': 3 (Freq: 71, Länge: 3)
  'i': 02 (Freq: 67, Länge: 3)
  'o': 12 (Freq: 64, Länge: 3)
  's': 010 (Freq: 61, Länge: 3)
  'a': 011 (Freq: 58, Länge: 3)
  'n': 100 (Freq: 56, Länge: 3)
  'r': 101 (Freq: 51, Länge: 3)
  'c': 110 (Freq: 44, Länge: 3)
  'd': 111 (Freq: 37, Länge: 3)
  'l': 4 (Freq: 33, Länge: 4)
  'm': 03 (Freq: 27, Länge: 4)
  'h': 13 (Freq: 26, Länge: 4)
  'u': 012 (Freq: 25, Länge: 4)
  'f': 102 (Freq: 20, Länge: 4)
  'p': 112 (Freq: 20, Länge: 4)
  'b': 5 (Freq: 16, Länge: 5)
  'y': 04 (Freq: 13, Länge: 5)
  'g': 14 (Freq: 11, Länge: 5)
  '': 013 (Freq: 8, Länge: 5)
  'v': 6 (Freq: 5, Länge: 6)
  'x': 05 (Freq: 5, Länge: 6)
  ',': 103 (Freq: 5, Länge: 5)
  'q': 113 (Freq: 5, Länge: 5)
  'w': 15 (Freq: 4, Länge: 6)
  'F': 014 (Freq: 3, Länge: 6)
  'T': 104 (Freq: 3, Länge: 6)
  '-': 06 (Freq: 1, Länge: 7)
  '1': 16 (Freq: 1, Länge: 7)

```

```

'A': 106 (Freq: 1, Länge: 8)
'G': 116 (Freq: 1, Länge: 8)
'2': 015 (Freq: 1, Länge: 7)
'5': 105 (Freq: 1, Länge: 7)
'9': 115 (Freq: 1, Länge: 7)
';': 016 (Freq: 1, Länge: 8)
'H': 1142 (Freq: 1, Länge: 8)
'S': 11400 (Freq: 1, Länge: 8)
'''': 11411 (Freq: 1, Länge: 8)
'j': 11401 (Freq: 1, Länge: 8)
'z': 11410 (Freq: 1, Länge: 8)
}

```

Gesamtlänge der Botschaft 3162 (in mm) bzw. 316.2cm

Kodierte Nachricht: 114000120303011101042104130201021120111120010121402600010201120300313121112102121012110121000103101012110302100142030210002030120306101001110121001110111001100421121010010202052110121110001021021210123130021400100001010114211102010110101003002100120201000400010010211013011100100004215023131201232110121000103101011021003010013210413002110120103010212102211012111002400330010101021000000111210012325002001130120114103201110011123130020100403512401020010011012111001112011101002100123201101001001203001112312250020011301201144042112101125011540001321062010124012302121002130111112112101006021201201040425000010021402600100250421142012102102030111002021002161151050152102121012313002010112001100201142110011010002021002151302110132011442110121110024003300101010201110100212102200113012011421101201030132104130021210100010001003211100600412112030010032020102011414005101011021100132014021010103103201031010121103012101002102012100110302121000102011101002111001020210000111103202100230010103010212102215130211013210000110000100100111010420111001112010012102102021100200100321101210011102302121000102102121012313002000502010300100110002121022112101001020205211012111000102030110425002010301130011101320141011203231300010002110121001110230212100010103240210000011101202100001130120114023020001020111010021110010102600111215130211013203011042500201201000111231221101301110101111030010102114100021121010010202052110121110001001321161203121010411411010202100300140010121121011214101011030302100142011414121010231303202010231300100201201000111231221101210001031010121103212112302030120321101211100010201001251140100110323122313000100020210000113012011402302000100162011100200400140111003211012035021000113121010201142011112112101120111101323122125301102100201120103101021103404211012031120123011302121000114200051120010102001001100020201021121010001000100300111231221110003121000103101011300231300211210101111030211001150240230421210223130020300313121110132014021000114404103201012030020111111102302121000114211012111021001421121011254000301020111010021110201011012010010001112011100111201121121011254000321210221104011010010021020211001130212102020102310100011300111013

Dieses Ergebnis (3162) ist der Vergleichswert (3162) von der BwInf Webseite, dies bestätigt die Vermutung, dass der angegebene Wert die optimale Kodierungslänge ist :)

6. schmuck6.txt

Ich habe es nicht geschafft, dass Unicodezeichen hier in einem verbatim in latex angezeigt werden, daher sind die Zeichen leer. In der Textdatei mit den gesamten Ausgaben, sind diese Zeichen sichtbar.

1. Preprocessing

k = 34, C = 3, n=3, S0 = (0; 1, 1, 1)

2a. Running Dynamic Programming (Dijkstra-like)

Reached target finalState = (34; 0, 0, 0) with cost 234

2b. DP Finished. Processed 2496 states

Total states in OPT table: 1892

3. Minimum Total Cost (Sum Freq*Depth): 234

4. Reconstructing Code

Reconstructing path

 Execution time: 99 ms

```
{
  "": 02 (Freq: 3, Länge: 4)
  "": 12 (Freq: 2, Länge: 5)
  "": 21 (Freq: 2, Länge: 5)
  "": 002 (Freq: 2, Länge: 5)
  "": 011 (Freq: 2, Länge: 5)
  "": 22 (Freq: 1, Länge: 6)
  "": 101 (Freq: 1, Länge: 5)
  "": 110 (Freq: 1, Länge: 5)
  "": 200 (Freq: 1, Länge: 5)
  "": 112 (Freq: 1, Länge: 7)
  "": 102 (Freq: 1, Länge: 6)
  "": 111 (Freq: 1, Länge: 6)
  "": 202 (Freq: 1, Länge: 7)
  "": 012 (Freq: 1, Länge: 6)
  "": 201 (Freq: 1, Länge: 6)
  "": 1001 (Freq: 1, Länge: 6)
  "": 1002 (Freq: 1, Länge: 7)
  "": 0011 (Freq: 1, Länge: 6)
  "": 0101 (Freq: 1, Länge: 6)
  "": 0012 (Freq: 1, Länge: 7)
  "": 0102 (Freq: 1, Länge: 7)
  "": 0002 (Freq: 1, Länge: 6)
  "": 01001 (Freq: 1, Länge: 7)
  "": 00001 (Freq: 1, Länge: 6)
  "": 00010 (Freq: 1, Länge: 6)
  "": 10001 (Freq: 1, Länge: 7)
  "": 01000 (Freq: 1, Länge: 6)
  "": 10000 (Freq: 1, Länge: 6)
  "": 00101 (Freq: 1, Länge: 7)
  "": 00100 (Freq: 1, Länge: 6)
  "": 00002 (Freq: 1, Länge: 7)
  "": 00011 (Freq: 1, Länge: 7)
  "": 000001 (Freq: 1, Länge: 7)
  "": 000000 (Freq: 1, Länge: 6)
}
```

Gesamtlänge der Botschaft 234 (in mm) bzw. 23.4cm

Kodierte Nachricht: 10201020100100100100210010200011000000111010102100010100000101202
 00112100021010111000000010112000022001200001212200220100201102110001201200000112

7. schmuck7.txt

1. Preprocessing
 - k = 82, C = 4, n=10, S0 = (0; 7, 1, 1, 1)
- 2a. Running Dynamic Programming (Dijkstra-like)
 - Reached target finalState = (82; 0, 0, 0, 0) with cost 134559
- 2b. DP Finished. Processed 205 states
 - Total states in OPT table: 476
3. Minimum Total Cost (Sum Freq*Depth): 134559
4. Reconstructing Code
 - Reconstructing path

```
-----  
Execution time: 270 ms  
-----
```

```
{  
  '□': 0 (Freq: 13488, Länge: 1)  
  'e': 1 (Freq: 11480, Länge: 1)  
  'n': 2 (Freq: 7761, Länge: 1)  
  'i': 3 (Freq: 5018, Länge: 1)  
  'r': 7 (Freq: 4011, Länge: 2)  
  's': 40 (Freq: 3507, Länge: 2)  
  'a': 41 (Freq: 3307, Länge: 2)  
  'd': 42 (Freq: 3272, Länge: 2)  
  'h': 43 (Freq: 3213, Länge: 2)  
  't': 44 (Freq: 3174, Länge: 2)  
  'u': 45 (Freq: 2609, Länge: 2)  
  'l': 46 (Freq: 2448, Länge: 2)  
  'c': 50 (Freq: 1991, Länge: 2)  
  'g': 51 (Freq: 1665, Länge: 2)  
  'm': 52 (Freq: 1521, Länge: 2)  
  'o': 53 (Freq: 1304, Länge: 2)  
  'b': 54 (Freq: 1141, Länge: 2)  
  ',': 55 (Freq: 1077, Länge: 2)  
  'f': 56 (Freq: 1000, Länge: 2)  
  'w': 60 (Freq: 941, Länge: 2)  
  '.': 61 (Freq: 831, Länge: 2)  
  'k': 62 (Freq: 798, Länge: 2)  
  'z': 63 (Freq: 631, Länge: 2)  
  'S': 8 (Freq: 498, Länge: 3)  
  'ä': 47 (Freq: 455, Länge: 3)  
  'ü': 57 (Freq: 434, Länge: 3)  
  'ö': 67 (Freq: 399, Länge: 3)  
  'v': 640 (Freq: 361, Länge: 3)  
  'F': 641 (Freq: 300, Länge: 3)  
  'p': 642 (Freq: 300, Länge: 3)  
  'ß': 643 (Freq: 278, Länge: 3)  
  'D': 644 (Freq: 277, Länge: 3)  
  'E': 645 (Freq: 243, Länge: 3)  
  'V': 646 (Freq: 242, Länge: 3)  
  'W': 650 (Freq: 231, Länge: 3)  
  'N': 651 (Freq: 218, Länge: 3)  
  'K': 652 (Freq: 206, Länge: 3)  
  'B': 653 (Freq: 193, Länge: 3)  
  'A': 654 (Freq: 159, Länge: 3)  
  'M': 655 (Freq: 159, Länge: 3)  
  'H': 656 (Freq: 152, Länge: 3)  
  'I': 660 (Freq: 134, Länge: 3)  
  'L': 661 (Freq: 126, Länge: 3)  
  'R': 662 (Freq: 115, Länge: 3)  
  'G': 663 (Freq: 106, Länge: 3)  
  'T': 664 (Freq: 102, Länge: 3)  
  'Z': 9 (Freq: 79, Länge: 4)  
  'j': 48 (Freq: 72, Länge: 4)  
  'J': 58 (Freq: 68, Länge: 4)  
  '-': 68 (Freq: 66, Länge: 4)  
  ';': 647 (Freq: 37, Länge: 4)  
  '(': 657 (Freq: 32, Länge: 4)  
  ')': 667 (Freq: 32, Länge: 4)  
  ':': 6650 (Freq: 28, Länge: 4)
```

```

'_: 6651 (Freq: 28, Länge: 4)
'0': 6652 (Freq: 27, Länge: 4)
'U': 6653 (Freq: 25, Länge: 4)
'[': 6654 (Freq: 24, Länge: 4)
']': 6655 (Freq: 24, Länge: 4)
'“': 6656 (Freq: 21, Länge: 4)
',,: 6660 (Freq: 21, Länge: 4)
'P': 6661 (Freq: 20, Länge: 4)
'1': 6662 (Freq: 16, Länge: 4)
'4': 6663 (Freq: 13, Länge: 4)
'3': 6664 (Freq: 9, Länge: 4)
'?': 6665 (Freq: 8, Länge: 4)
'!': 49 (Freq: 7, Länge: 5)
'2': 59 (Freq: 7, Länge: 5)
'5': 69 (Freq: 7, Länge: 5)
'6': 648 (Freq: 6, Länge: 5)
'0': 658 (Freq: 5, Länge: 5)
'8': 668 (Freq: 3, Länge: 5)
'Ä': 6667 (Freq: 3, Länge: 5)
'q': 6657 (Freq: 3, Länge: 5)
'": 66663 (Freq: 2, Länge: 5)
'7': 66660 (Freq: 2, Länge: 5)
'9': 66661 (Freq: 2, Länge: 5)
'Q': 66662 (Freq: 2, Länge: 5)
'Ö': 649 (Freq: 1, Länge: 6)
'C': 66664 (Freq: 1, Länge: 5)
'x': 66665 (Freq: 1, Länge: 5)
'y': 66666 (Freq: 1, Länge: 5)
}

```

Gesamtlänge der Botschaft 134559 (in mm) bzw. 13455.9cm

Kodierte Nachricht: 654454004215206611541204524017170646675114661066116244353206...
(die kodierte Nachricht ist mehr als 110KB)

8. schmuck8.txt

1. Preprocessing

k = 321, C = 3, n=5, S0 = (0; 2, 2, 1)

2a. Running Dynamic Programming (Dijkstra-like)

Processed 30000 states (pop ops), PQ size 372225

Processed 60000 states (pop ops), PQ size 664988

Processed 90000 states (pop ops), PQ size 803740

...

Processed 900000 states (pop ops), PQ size 674085

Processed 930000 states (pop ops), PQ size 644298

Processed 990000 states (pop ops), PQ size 586335

Processed 1110000 states (pop ops), PQ size 468469

Processed 1170000 states (pop ops), PQ size 408474

Reached target finalState = (321; 0, 0, 0) with cost 3287

2b. DP Finished. Processed 1188509 states

Total states in OPT table: 1059938

3. Minimum Total Cost (Sum Freq*Depth): 3287

4. Reconstructing Code

Reconstructing path

Execution time: 38.298 s

{

```

": 4 (Freq: 33, Länge: 3)
": 02 (Freq: 27, Länge: 3)
": 04 (Freq: 13, Länge: 4)
": 14 (Freq: 13, Länge: 4)
": 22 (Freq: 12, Länge: 4)
": 23 (Freq: 11, Länge: 4)
": 32 (Freq: 11, Länge: 4)
": 33 (Freq: 10, Länge: 4)
": 002 (Freq: 10, Länge: 4)
": 003 (Freq: 9, Länge: 4)
": 012 (Freq: 7, Länge: 4)
": 030 (Freq: 7, Länge: 4)
": 013 (Freq: 7, Länge: 4)
": 34 (Freq: 6, Länge: 5)
": 24 (Freq: 6, Länge: 5)
": 031 (Freq: 6, Länge: 4)
": 033 (Freq: 5, Länge: 5)
": 104 (Freq: 5, Länge: 5)
": 004 (Freq: 5, Länge: 5)
": 032 (Freq: 5, Länge: 5)
": 014 (Freq: 5, Länge: 5)
": 132 (Freq: 4, Länge: 5)
": 114 (Freq: 4, Länge: 5)
": 202 (Freq: 4, Länge: 5)

```

...

```

": 000113 (Freq: 1, Länge: 7)
": 110001 (Freq: 1, Länge: 6)
": 101101 (Freq: 1, Länge: 6)
": 100100 (Freq: 1, Länge: 6)
": 010000 (Freq: 1, Länge: 6)
": 000000 (Freq: 1, Länge: 6)
": 110111 (Freq: 1, Länge: 6)
": 101003 (Freq: 1, Länge: 7)
": 101012 (Freq: 1, Länge: 7)
": 011111 (Freq: 1, Länge: 6)
": 011112 (Freq: 1, Länge: 7)
": 101013 (Freq: 1, Länge: 7)
": 101102 (Freq: 1, Länge: 7)
": 011113 (Freq: 1, Länge: 7)
": 000001 (Freq: 1, Länge: 6)
": 000002 (Freq: 1, Länge: 7)
": 000010 (Freq: 1, Länge: 6)
": 001002 (Freq: 1, Länge: 7)
": 001010 (Freq: 1, Länge: 6)
": 101110 (Freq: 1, Länge: 6)
": 000003 (Freq: 1, Länge: 7)
": 000011 (Freq: 1, Länge: 6)
": 010110 (Freq: 1, Länge: 6)
": 110112 (Freq: 1, Länge: 7)

```

}

Gesamtlänge der Botschaft 3287 (in mm) bzw. 328.7cm

Kodierte Nachricht: 010020001031100030103100003344102131420103010411321101011001130...

1. Preprocessing

$k = 674$, $C = 4$, $n=4$, $S_0 = (0; 1, 1, 1, 1)$

2a. Running Dynamic Programming (Dijkstra-like)

Processed 30000 states (pop ops), PQ size 257044

Processed 60000 states (pop ops), PQ size 666081

Processed 90000 states (pop ops), PQ size 1315271

Processed 120000 states (pop ops), PQ size 1524169

Processed 150000 states (pop ops), PQ size 1631613

...

Processed 7230000 states (pop ops), PQ size 56443913

Processed 7260000 states (pop ops), PQ size 56748051

Processed 7290000 states (pop ops), PQ size 57033159

Processed 7320000 states (pop ops), PQ size 57361366

Processed 7350000 states (pop ops), PQ size 57750525

Processed 7380000 states (pop ops), PQ size 58057696

Processed 7410000 states (pop ops), PQ size 58362853

Processed 7440000 states (pop ops), PQ size 58707514

Ab hier habe ich abgebrochen.

Diese Lösungsansatz ist mit Werten von $k = 674$, $C = 4$, $n = 4$, $S_0 = (0; 1, 1, 1, 1)$ und einer Laufzeit von $\mathcal{O}(C \cdot k^{C+2}) = \mathcal{O}(4 \cdot 674^6)$ und mit einem Speicherbedarf von $\mathcal{O}(4 \cdot 674^5)$ nicht mehr realistisch. Der benötigte Speicher wäre im Größenbereich von Petabytes an RAM, (aber hängt davon ab wie viele Zustände tatsächlich erreicht werden: Landau-Notation ist nur eine obere Schranke)

2.4.5 Quellcode

Wichtige Teile des Quellcodes:

Die wichtigsten WrapperKlassen

```

1 // Represent Signature state in algorithm. Signature holds important info about code
  tree construction at level i.
2 class Signature {
3     final int m;
4     final List<Integer> list; // Represent l1, l2, ..., lC
5     // l1: amount of leaves on depth i + 1
6     // l2: amount of leaves on depth i + 2 ...
7     private final int C; // Maximum cost of any alphabet symbol
8
9     public Signature(int m, List<Integer> ls) {
10         // Represents amount of leaves (final codewords), that are on depth <= i
11         this.m = m;
12         // Ensure immutability for use as key
13         this.list = Collections.unmodifiableList(new ArrayList<>(ls));
14         this.C = ls.size();
15     }
16
17     public int getC() {
18         return C;
19     }
20
21     public int getL(int index) {
22         return (index >= 0 && index < list.size()) ? list.get(index) : 0;
23     }
24
25     ...
26 }
27
28 // Used in PriorityQueue for Dijkstra like loop
29 // Wrapper to hold cost to get to a signature
30 class StateCost implements Comparable<StateCost> {
31     // Cost needed to get to signature
32     final long cost;

```

```

33     final Signature signature;

35     public StateCost(long cost, Signature signature) {
36         this.cost = cost;
37         this.signature = signature;
38     }
39
40     ...
41 }

43 // Helper class for buildCodeFromDepths and represents a target
44 // Symbol at symbolIndex needs codeword with the specified depth
45 class TargetInfo implements Comparable<TargetInfo> {
46     // Required depth (cost) for codeword of the symbol
47     final int depth;
48     final int symbolIndex; // Original index in sorted symbol list
49
50     public TargetInfo(int depth, int symbolIndex) {
51         this.depth = depth;
52         this.symbolIndex = symbolIndex;
53     }
54
55     ...
56 }

```

Berechnung des charakteristischen Vektors d

```

// Calculate characteristic vector d and max cost C
2 private static CharacteristicVectorResult calculateCharacteristicVector(List<Integer>
   costs) {
3     if (costs == null || costs.isEmpty()) {
4         return new CharacteristicVectorResult(new int[0], 0);
5     }
6     // Find max C
7     int maxC = 0;
8     for (int cost : costs) {
9         if (cost > 0) {
10            maxC = Math.max(maxC, cost);
11        }
12    }
13    if (maxC == 0) {
14        return new CharacteristicVectorResult(new int[0], 0);
15    }
16
17    // Count occurrences of every positive cost up to maxC
18    int[] dCounts = new int[maxC + 1]; // dCounts[i] store count for cost i
19    for (int cost : costs) {
20        if (cost > 0) {
21            dCounts[cost]++;
22        }
23    }
24    // Create final 'd' array which starts from cost 1
25    int[] dResult = Arrays.copyOfRange(dCounts, 1, maxC + 1);
26    return new CharacteristicVectorResult(dResult, maxC);
27 }

```

Hauptmethode mit DP

```

1 // Main solver method
2 private static OptimalCodingResult solveOptimalCode(String text, List<Integer>
   alphabetCosts) {
3     // 1. Preprocessing step
4     System.out.println("1. Preprocessing");
5     // 1a. Calculate symbol frequencies
6     FrequencyResult freqResult = calculateFrequencies(text);
7     if (freqResult.sortedSymbols.isEmpty()) {
8         return new OptimalCodingResult(Collections.emptyMap(), 0, null, null);
9     }
10
11     // Num of unique symbols k

```



```

13     int k = freqResult.sortedSymbols.size();
14     // Frequency counts
15     long[] freqCounts =
16         freqResult.sortedSymbols.stream().mapToLong(Map.Entry::getValue).toArray();
17
18     // 1b. Precompute cumulative frequency counts (suffix sums)
19     // Needed for edge cost calculation in 0(1)
20     long[] cumFreq = new long[k + 1];
21     // cumFreq[i] = sum of frequencies from index i to n-1 (i.e., P_{i+1} + ... +
22     // P_n)
23     for (int i = k - 1; i >= 0; i--) {
24         cumFreq[i] = cumFreq[i + 1] + freqCounts[i];
25     }
26
27     // 1c. Calculate characteristic vector 'd' and maximum cost 'C'
28     CharacteristicVectorResult charVecResult =
29         calculateCharacteristicVector(alphabetCosts);
30     int[] d = charVecResult.d;
31     int C = charVecResult.C;
32     if (C == 0) {
33         System.err.println("Error: No valid alphabet costs provided (C=0).");
34         return new OptimalCodingResult(null, Long.MAX_VALUE, "Invalid alphabet costs",
35             null);
36     }
37     int r = alphabetCosts.size();
38
39     // 2. Build Zustandsgraph
40     // Explore signatures to find min cost path
41     // Simulate building optimal code tree top-down
42
43     // 2a. Init DP table (OPT) and Predecessor table (Pred)
44     // Saves minimal cost to get to a signature from S0
45     Map<Signature, Long> opt = new HashMap<>();
46     // Saves the current best way to get to a signature
47     Map<Signature, PredecessorInfo> pred = new HashMap<>();
48
49     // Calculate initial signature S0
50     // List full of 0
51     List<Integer> initialLsRaw = new ArrayList<>(Collections.nCopies(C, 0));
52     for (int i = 0; i < d.length; ++i) {
53         // Set initial to values of characteristic vector
54         initialLsRaw.set(i, d[i]); // d has length C
55     }
56     // Signature of "root"
57     Signature initialSigRaw = new Signature(0, initialLsRaw);
58     Signature S0 = reduceSignature(initialSigRaw, k);
59     opt.put(S0, 0L);
60
61     // Target sig: all Symbols in the tree have a codeword
62     Signature finalState = new Signature(k, Collections.nCopies(C, 0));
63
64     // Priority Queue for Dijkstra like (process states with lowest cost first)
65     PriorityQueue<StateCost> pq = new PriorityQueue<>();
66     pq.add(new StateCost(0L, S0));
67
68     System.out.println("n=" + k + ", C=" + C + ", r=" + r + ", S0=" + S0);
69     System.out.println("2a. Running Dynamic Programming (Dijkstra-like)");
70     long processedCount = 0;
71     // Store the actual final signature, to begin null, check after dp, if still
72     // null
73     Signature actualFinalSig = null;
74     // Store the final cost to get from S0 to final State
75     long finalCostFound = Long.MAX_VALUE;
76
77     // 2b. Main DP loop
78     while (!pq.isEmpty()) {
79         // Get state with smallest cost from queue
80         StateCost current = pq.poll();
81         long currentCost = current.cost;
82         Signature currentSig = current.signature;
83         processedCount++;
84
85         // If found a shorter path to a signature already, skip

```

```

83         if (currentCost > opt.getDefault(currentSig, Long.MAX_VALUE)) {
84             continue;
85         }
86
87         // Check if reached target state
88         if (currentSig.equals(finalState)) {
89             if (currentCost < finalCostFound) {
90                 finalCostFound = currentCost;
91                 actualFinalSig = currentSig;
92                 System.out.println("Reached target finalState=" + currentSig + "
with cost" + currentCost);
93                 break;
94             }
95         }
96
97         // Small optimization
98         if (actualFinalSig != null && currentCost >= finalCostFound)
99             continue;
100
101         // Logging
102         if (processedCount % 30000 == 0) {
103             System.out.println("Processed" + processedCount + "states(pop,ops),PQ
size" + pq.size());
104         }
105
106         // --- Generate next states
107         // Get data from current signature
108         int m = currentSig.m;
109         int l1 = currentSig.getL(0);
110
111         // Calculate cost added for expansion step (edge weight in state graph)
112         long edgeCost = (m < k) ? cumFreq[m] : 0;
113         long newBaseCost = currentCost + edgeCost;
114
115         // Iterate through possible expansions q
116         for (int q = 0; q <= l1; q++) {
117             // Get signature for an expansion
118             Signature nextSigRaw = getNextSigRaw(currentSig, q, d, C);
119             Signature nextSignature = reduceSignature(nextSigRaw, k);
120
121             // Update if a better path is found
122             if (newBaseCost < opt.getDefault(nextSignature, Long.MAX_VALUE)) {
123                 // Better cost was found to get to a signature
124                 opt.put(nextSignature, newBaseCost);
125                 // Store how to get to that signature
126                 pred.put(nextSignature, new PredecessorInfo(currentSig, q));
127                 // Add a new state to explore to pq
128                 pq.add(new StateCost(newBaseCost, nextSignature));
129             }
130         }
131
132         System.out.println("2b.DPFinished.Processed" + processedCount + "states");
133         System.out.println("Total states in OPT table:" + opt.size());
134
135         // 3. Get result and check if finalState was reached
136         if (actualFinalSig == null) {
137             // Check if anystate (n, 0, ..., 0) was reached if finalState was not hit
138             // directly
139             boolean foundEquivalent = false;
140             // Iterate over all signatures in opt and check if state was reached that is
141             // equivalent
142             for (Map.Entry<Signature, Long> entry : opt.entrySet()) {
143                 Signature sig = entry.getKey();
144                 // Check if m == n and all l_i == 0
145                 if (sig.m == k && sig.list.stream().allMatch(l -> l == 0)) {
146                     if (entry.getValue() < finalCostFound) {
147                         finalCostFound = entry.getValue();
148                         actualFinalSig = sig;
149                         foundEquivalent = true;
150                     }
151                 }
152             }
153         }
154     }

```

```

153         if (foundEquivalent) {
154             System.out.println(
155                 "Reached equivalent final state" + actualFinalSig + " with cost "
156                 + finalCostFound);
157         } else {
158             System.out.println("Error: Target signature final state not reached");
159             return new OptimalCodingResult(null, Long.MAX_VALUE, "Target state not
160             reachable", null);
161         }
162     }
163
164     // Optimal cost found by DP
165     long minTotalCost = finalCostFound;
166     System.out.println("3. Minimum Total Cost (Sum Freq*Depth):" + minTotalCost);
167
168     // 4. Reconstruct code
169     System.out.println("4. Reconstructing Code");
170     // Reconstruct path and determine leaf depths
171     // Simulates the optimal tree construction process based on pred map
172     Map<Integer, Long> leafDepthsCounts = getLeafDepthsFromPath(actualFinalSig, pred,
173     S0, k, d, alphabetCosts);
174
175     // Error
176     if (leafDepthsCounts == null) {
177         System.out.println("Error: (Failed to reconstruct leaf depths)");
178         return new OptimalCodingResult(null, minTotalCost, "Leaf depth reconstruction
179         failed", null);
180     }
181
182     // 5b. Create actual code table using determined dpeths
183     Map<Character, String> codeTable = buildCodeFromDepths(freqResult.sortedSymbols,
184     leafDepthsCounts,
185     alphabetCosts);
186
187     if (codeTable == null) {
188         System.err.println("Failed to assign codewords from depths.");
189         return new OptimalCodingResult(null, minTotalCost, "Codeword assignment failed",
190         null);
191     }
192
193     return new OptimalCodingResult(codeTable, minTotalCost, null, freqResult.counts);
194 }

```

Rekonstruktion der Blatttiefen

```

// ----- Reconstruction of tree and Code Assignment
2
// Step 4
4 // Trace back path from finalSig to S0 and simulate tree construction to find
// leaf depths
6 // Then simulates tree construction process (forward) along this optimal path to
// find exact depth at which each of the n leaves is finalized
8 private static Map<Integer, Long> getLeafDepthsFromPath(
    Signature finalSig, Map<Signature, PredecessorInfo> pred, Signature S0,
10     int n, int[] characVector, List<Integer> alphabetCosts) {
    System.out.println("Reconstructing path");
12     List<PredecessorInfo> path = new ArrayList<>();
    Signature currentSignature = finalSig;
14
15     // 4a. Backtrack from final state to S0 with pred map
16     while (!currentSignature.equals(S0)) {
17         PredecessorInfo info = pred.get(currentSignature);
18         if (info == null) {
19             System.out.println(
20                 "Error: Cannot backtrack from signature" + currentSignature + ";
21                 failed");
22             return null;
23         }
24         // Add info about step to current Sign
25         path.add(info);
26         currentSignature = info.previousSignature;
    }
}

```

```

28 // Path currently in reverse order (final -> S0), reverse here for forward
// simulation
Collections.reverse(path);

30
31 if (path.isEmpty() && S0.equals(finalSig)) {
32     // Handle n=0 or n=1 case where path might be empty
33     return (S0.m == n) ? new HashMap<>() : null;
34 }

35
36 // 4b. --- Simulate forward construction
// Store final result
37 Map<Integer, Long> leavesFinishedAtDepth = new HashMap<>();
38 // Track currently open end (potentiall leaves) and their depths during
// simulation
40 Map<Integer, Long> activeLeaves = new HashMap<>();

41
42 // Init active leaves based on initial state S0 (after reduction)
43 // Need to know wich children root has according to S0
Signature unreducedS0 = new Signature(0,
44 Arrays.stream(characVector).boxed().collect(Collectors.toList()));
45 if (S0.equals(unreducedS0)) {
46     for (int cost : alphabetCosts) {
47         if (cost > 0)
48             activeLeaves.put(cost, activeLeaves.getOrDefault(cost, 0L) + 1);
49     }
50 } else {
51     Map<Integer, Long> tempActive = new HashMap<>();
52     for (int cost : alphabetCosts) {
53         if (cost > 0)
54             tempActive.put(cost, tempActive.getOrDefault(cost, 0L) + 1);
55     }
56     long currentTotal = 0;
57     List<Integer> sortedDepths = new ArrayList<>(tempActive.keySet());
58     Collections.sort(sortedDepths);
59     for (int depth : sortedDepths) {
60         long countAtDepth = tempActive.get(depth);
61         long canKeep = n - currentTotal;
62         long keep = Math.min(countAtDepth, canKeep);
63         if (keep > 0) {
64             activeLeaves.put(depth, keep);
65             currentTotal += keep;
66         }
67         if (currentTotal >= n)
68             break;
69     }
70 }

71
72 // Simulate forward along path
73 int currentLevel = 0; // Track implicit level of signatures
74 for (PredecessorInfo info : path) {
75     // Optimal expansion for this step
76     int q = info.q;
77     int simDepth = currentLevel + 1;
78
79     long numActiveAtSimDepth = activeLeaves.getOrDefault(simDepth, 0L);
80
81     // Determine how many nodes at simDepth expand or finalize
82     long nodesToExpand = Math.min(q, numActiveAtSimDepth);
83     long nodesToFinalize = numActiveAtSimDepth - nodesToExpand;
84
85     // Update active leaves
86     activeLeaves.remove(simDepth);
87
88     // Add children of expanded nodes to active leaves
89     for (int i = 0; i < nodesToExpand; i++) {
90         for (int cost : alphabetCosts) {
91             if (cost > 0)
92                 activeLeaves.put(simDepth + cost, activeLeaves.getOrDefault(simDepth
+ cost, 0L) + 1);
93         }
94     }
95
96     // Simulate Reduction

```

```

98     long currentFinishedCount =
leavesFinishedAtDepth.values().stream().mapToLong(Long::longValue).sum();
    long currentActiveCount =
activeLeaves.values().stream().mapToLong(Long::longValue).sum();
100    long potentialTotal = currentFinishedCount + currentActiveCount +
nodesToFinalize;
    // How man leaves to remove to stay in n
102    long leavesToRemove = Math.max(0, potentialTotal - n);

104    // Remove deepest leaves first
    long removedCount = 0;
106    if (leavesToRemove > 0) {
        List<Integer> sortedActiveDepths = new ArrayList<>(activeLeaves.keySet());
108        sortedActiveDepths.sort(Collections.reverseOrder()); // Deepest first, ->
takes most of runtime when                                     // timecomplexity is
viewed
110        for (int depth : sortedActiveDepths) {
            // Removed enough
112            if (removedCount >= leavesToRemove)
                break; //
114            long canRemoveAtDepth = activeLeaves.get(depth);
            long removeNow = Math.min(leavesToRemove - removedCount,
canRemoveAtDepth);
116            activeLeaves.put(depth, activeLeaves.get(depth) - removeNow);
            if (activeLeaves.get(depth) == 0) {
118                activeLeaves.remove(depth);
            }
120            removedCount += removeNow;
        }
122    }

124    long nodesFinalizedThisStep = Math.max(0, nodesToFinalize - (leavesToRemove -
removedCount));

126    if (nodesFinalizedThisStep > 0) {
        leavesFinishedAtDepth.put(simDepth,
128            leavesFinishedAtDepth.getOrDefault(simDepth, 0L) +
nodesFinalizedThisStep);
    }
130    // Move to next level
    currentLevel++;
132 }

134 // After loop any remaining active leaves are finalized leaves
for (Map.Entry<Integer, Long> entry : activeLeaves.entrySet()) {
136     leavesFinishedAtDepth.put(entry.getKey(),
        leavesFinishedAtDepth.getOrDefault(entry.getKey(), 0L) +
entry.getValue());
138 }

140 // Verify
long totalLeavesReconstructed =
leavesFinishedAtDepth.values().stream().mapToLong(Long::longValue).sum();
142 if (totalLeavesReconstructed != n) {
    System.err.println(
144         "Warning: Reconstructed " + totalLeavesReconstructed + " leaves, but
expected " + n);
}
146
return leavesFinishedAtDepth;
148 }

```

Generierung der Codetabelle

```

// 5. Construct prefix free code
2 public static Map<Character, String> buildCodeFromDepths(
    List<Map.Entry<Character, Long>> symbolFreqs,
4     Map<Integer, Long> depthsCounts,
    List<Integer> costs) {
6     if (symbolFreqs == null || symbolFreqs.isEmpty() || depthsCounts == null ||
depthsCounts.isEmpty()) {

```

```

    return Collections.emptyMap();
}

int n = symbolFreqs.size();
int r = costs.size();
List<Character> symbols =
symbolFreqs.stream().map(Map.Entry::getKey).collect(Collectors.toList());

// Create and sort targets
// Every entry represents one required leaf: targetDepth, symbolIndex
List<TargetInfo> targets = new ArrayList<>();
int symbolIdx = 0;
int maxTargetDepth = 0;
List<Integer> sortedDepths = new ArrayList<>(depthsCounts.keySet());
Collections.sort(sortedDepths);

for (int depth : sortedDepths) {
    // How many leaves are needed at this depth
    long count = depthsCounts.get(depth);
    maxTargetDepth = Math.max(maxTargetDepth, depth);
    for (int i = 0; i < count; i++) {
        if (symbolIdx < n) {
            targets.add(new TargetInfo(depth, symbolIdx));
            symbolIdx++;
        } else {
            System.out.println("Error: More depths specified than symbols");
            break;
        }
    }
    if (symbolIdx >= n)
        break;
}

// Sort by depth, then symbol index
Collections.sort(targets);

// Generate and assign codes greedily
Map<Character, String> codeMap = new HashMap<>();
List<String> assignedCodesList = new ArrayList<>(); // For prefix checks

// Use queue for BFS like generation of candidate codewords
Deque<String> generatorQueue = new ArrayDeque<>();
// Start with single digit codes (children of root)
for (int i = 0; i < r; i++) {
    generatorQueue.offerLast(String.valueOf(i));
}

// Pool to store codewords that have wrong cost for current target but match
// maybe later
Map<Integer, Deque<String>> candidatePool = new HashMap<>();

// Maximum generation limit to prevent infinite loops
int minCost = Integer.MAX_VALUE;
for (int cost : costs) {
    if (cost > 0) {
        minCost = Math.min(minCost, cost);
    }
}
if (minCost == Integer.MAX_VALUE) {
    minCost = 1; // Avoid durch null teilen
}

// Estimate max length needed plus 2 buffer
int worstCaseLen = (maxTargetDepth > 0) ? (maxTargetDepth / minCost + 2) : 1;
// Estimate of max nodes in full tree of that length and set cap
long MaxGeneratedNodes = (long) Math.min(10000000, Math.max(n * 10L, (long)
Math.pow(r, worstCaseLen + 1)));
long generatedCount = 0;

// Iterate through targets and assign next available code
for (TargetInfo target : targets) {
    int targetDepth = target.depth;
    int targetSymbolIndex = target.symbolIndex;
    char targetSymbol = symbols.get(targetSymbolIndex);

```

```

78     boolean foundCodeForTarget = false;

80     // 1. Check candidate pool
81     Deque<String> poolDeque = candidatePool.get(targetDepth);
82     if (poolDeque != null && !poolDeque.isEmpty()) {
83         // Temp store codes that fail prefix check
84         Deque<String> skipped = new ArrayDeque<>();
85         while (!poolDeque.isEmpty()) {
86             String candidate = poolDeque.pollFirst();
87             boolean isPrefixFree = true;
88             // Check if it actually is prefix free with already assigned codes
89             for (String assigned : assignedCodesList) {
90                 // Not prefix free
91                 if (candidate.startsWith(assigned) ||
92 assigned.startsWith(candidate)) {
93                     isPrefixFree = false;
94                     break;
95                 }
96             }
97             if (isPrefixFree) {
98                 // Found usable code
99                 codeMap.put(targetSymbol, candidate);
100                assignedCodesList.add(candidate);
101                foundCodeForTarget = true;
102                break;
103            } else {
104                // If fails prefix, but aside for a little
105                skipped.offerLast(candidate);
106            }
107        }
108        // Put skipped back into pool (maybe used later)
109        while (!skipped.isEmpty()) {
110            poolDeque.offerLast(skipped.pollFirst());
111        }
112    }

113    // 2. Generate new codes if needed
114    // If no fitting code was in pool, create new candidates
115    if (!foundCodeForTarget) {
116        while (generatedCount < MaxGeneratedNodes) {
117            String codeword;
118            // Problem
119            if (generatorQueue.isEmpty()) {
120                System.out.println("Error: Code generator queue empty????");
121                return null;
122            }
123            // Dequeue next shortest prefix
124            String current = generatorQueue.pollFirst();
125            for (int i = 0; i < r; i++) {
126                generatorQueue.offerLast(current + i);
127            }
128            // Use dequeued item as current candidate
129            codeword = current;

130            generatedCount++;
131            long currentCost = calculateCost(codeword, costs);
132            // Invalid cost
133            if (currentCost == Long.MAX_VALUE) {
134                continue;
135            }
136            // Check if cost matches target depth
137            if (currentCost == targetDepth) {
138                boolean isPrefixFree = true;
139                // Check if prefix free
140                for (String assigned : assignedCodesList) {
141                    if (codeword.startsWith(assigned) ||
142 assigned.startsWith(codeword)) {
143                        isPrefixFree = false;
144                        break;
145                    }
146                }
147                if (isPrefixFree) {
148                    // Found code

```

```

150         codeMap.put(targetSymbol, codeword);
151         assignedCodesList.add(codeword);
152         foundCodeForTarget = true;
153         break;
154     } else {
155         // Correct cost but not prefix free, maybe used later -> put in
156         pool
157         candidatePool.computeIfAbsent((int) currentCost, k -> new
158         ArrayDeque<>())
159             .offerLast(codeword);
160     } else {
161         candidatePool.computeIfAbsent((int) currentCost, k -> new
162         ArrayDeque<>()).offerLast(codeword);
163     }
164     }
165     if (!foundCodeForTarget && generatedCount >= MaxGeneratedNodes) {
166         System.out.println(
167             "Error: Max generation limit (" + MaxGeneratedNodes + ") reached
168             for depth " + targetDepth);
169         return null;
170     }
171     if (!foundCodeForTarget) {
172         System.out.println(
173             "FATAL: Failed to find code for symbol " + targetSymbol + " depth "
174             + targetDepth);
175         return null;
176     }
177     }
178     // Final check if all symbols received codes
179     if (codeMap.size() == n) {
180         return codeMap;
181     } else {
182         System.out.println(
183             "Error: Assignment loop finished but only assigned " + codeMap.size() +
184             "/" + n + " codes");
185         return null;
186     }
187 }

```

Kleinere Hilfsmethoden die oben verwendet werden

```

2 // Apply reduce operation to signature
3 // Ensures that signature represents at most n leaves
4 private static Signature reduceSignature(Signature signature, int n) {
5     int m = signature.m;
6     int C = signature.getC();
7
8     // Ensure m is not exceeding n to begin with
9     int mPrime = Math.min(m, n);
10    List<Integer> lsPrime = new ArrayList<>(Collections.nCopies(C, 0)); // Init with
11    zeros
12    long currentSum = mPrime; // Had overflow problem with int
13
14    // Iterate through levels l_1, l_2 ..., l_C
15    for (int j = 0; j < C; j++) { // j maps to l_{j+1}
16        int l_j_plus_1 = signature.getL(j); // ls.get(j)
17
18        // Ensure not exceeding n leaves
19        long remainingCapacity = n - currentSum;
20        // Get new count
21        int l_prime_j_plus_1 = (int) Math.max(0, Math.min(l_j_plus_1,
22        remainingCapacity));
23
24        lsPrime.set(j, l_prime_j_plus_1);
25        currentSum += l_prime_j_plus_1;
26    }
27 }

```



```

24     return new Signature(mPrime, lsPrime);
25 }
26
27 // Calculate next raw signature before reduction
28 private static Signature getNextSigRaw(Signature signature, int q, int[] d, int C) {
29     int m = signature.m;
30     int dLen = d.length; // d represent costs 1 to C
31
32     int l1 = signature.getL(0); // l1 is at index 0
33     int mPrime = m + l1 - q;
34     List<Integer> lsPrime = new ArrayList<>(Collections.nCopies(C, 0)); // Initit with
35     zeros
36
37     // 1. Shift l's
38     for (int k = 0; k < C - 1; k++) { // k from 0 to C-2 relates to l'_1 to l'_{C-1}
39         lsPrime.set(k, signature.getL(k + 1));
40     }
41
42     // 2. Add new leaves by expanding q nodes
43     // Based on characteristic vector
44     for (int k = 0; k < C; k++) { // k from 0 to C-1 relates to d_1 to d_C
45         if (k < dLen) { // Check bounds for d (d has length C)
46             int currentVal = lsPrime.get(k);
47             lsPrime.set(k, currentVal + (q * d[k]));
48         }
49     }
50     return new Signature(mPrime, lsPrime);
51 }
52
53 // Calculate cost of one codeword
54 private static long calculateCost(String codewordStr, List<Integer> costs) {
55     long cost = 0;
56     int r = costs.size();
57     for (int i = 0; i < codewordStr.length(); i++) {
58         char digitChar = codewordStr.charAt(i);
59         int digit = Character.getNumericValue(digitChar);
60         if (digit >= 0 && digit < r) {
61             cost += costs.get(digit);
62         } else {
63             // Invalid
64             System.out.println(
65                 "Warning: Invalid digit '" + digitChar + "' in codeword '" +
66                 codewordStr + ", at this point might aswell just quit");
67             return Long.MAX_VALUE;
68         }
69     }
70     return cost;
71 }

```

2.5 Vergleich der Strategien

- **Strategie 1** ist die einfachste Lösung, führt jedoch, wie zu erwarten war, zu den schlechtesten Ergebnissen. Nur die Optimierung der Kantenzuweisung auf einem frequenzbasierten Baum reicht, um die Kosten effektiv zu berücksichtigen (Beispiel *schmuck5.txt*: 4010 vs. 3162).
- **Strategie 2** zeigt eine deutliche Verbesserung im Vergleich zu Strategie 1. Durch die Berücksichtigung der Kosten bei der rekursiven Aufteilung mit der charakteristischen Wurzel c kann eine bessere Annäherung an die optimale Lösung erreicht werden (Beispiel *schmuck5.txt*: 3374). Diese Methode bietet allerdings keine Garantie für die Optimalität der Lösung. Dies spiegelt sich auch in den Ergebnissen im Vergleich zu den optimalen Werten wider. Die Laufzeit bleibt dabei aber sehr gut.
- **Strategie 3** ist mit Abstand am aufwendigsten in der Implementierung und hat die höchste theoretische Zeit- und Speicherkomplexität. Da es notwendig ist, einen großen Zustandsraum (potenziell $\mathcal{O}(C \cdot k^{C+1})$ Signaturen) zu speichern, begrenzt dies die praktische Anwendbarkeit bei sehr großen k und auch für größere C . Dennoch ist dies der einzige der drei Ansätze, der garantiert die optimale Lösung liefert. Das Ergebnis für das Beispiel *schmuck5.txt* (3162 Perlen), stimmt

mit dem Referenzwert auf der BwInf-Webseite überein. Bei den restlichen Beispielen erzielt diese Methode die besten Ergebnisse.

Daher ist es sinnvoll die dritte Strategie anzuwenden, wenn die Eingabegrößen im Rahmen sind. Ansonsten sollte Strategie 2 verwendet werden.

Kriterium	Strategie 1 (Heuristik)	Strategie 2 (Golin/Li)	Strategie 3 (Golin/Rote)
Optimalität	Nein (Heuristik)	Nein (Heuristik/Vereinf.)	Ja (wenn Kosten $\in \mathbb{N}$)
Laufzeit (Theorie)	Schnell $\mathcal{O}(L + k \log k)$	Schnell $\mathcal{O}(L + k \log k + n)$	Hoch $\mathcal{O}(C \cdot k^{C+2})$
Speicher (Theorie)	Gering $\mathcal{O}(L + k)$	Mittel $\mathcal{O}(L + k + n + k \log k)$	Hoch $\mathcal{O}(C \cdot k^{C+1})$
Implementierung	Einfach	Mittel	Schwer
Ergebnis (Bsp. schmuck5)	Deutlich suboptimal (4010 Perlen)	Besser als S1, suboptimal (3374 Perlen)	Optimal (3162 Perlen)

Table 5: Vergleich der implementierten Strategien für Teilaufgabe B

References

- [1] David A. Huffman (1952) *A Method for the Construction of Minimum-Redundancy Codes*, *Proceedings of the IRE*, 40(9), 1098–1101. <https://doi.org/10.1109/JRPROC.1952.273898>
- [2] Mordecai Golin and Li Jian (2007) *More Efficient Algorithms and Analyses for Unequal Letter Cost Prefix-Free Coding*, arXiv:0705.0253 [cs.IT]. <https://doi.org/10.48550/arXiv.0705.0253>
- [3] M. J. Golin and G. Rote (1998) *A dynamic programming algorithm for constructing optimal prefix-free codes with unequal letter costs*, *IEEE Transactions on Information Theory*, 44(5), 1770–1781. <https://doi.org/10.1109/18.705558>